

Методы машинного обучения (ММО)

Линейные модели регрессии

Воронцов Константин Вячеславович

www.MachineLearning.ru/wiki?title=User:Vokov

вопросы к лектору: vorontsovk@my.msu.ru

материалы курса:

github.com/MSU-ML-COURSE/ML-COURSE-26-27

орг.вопросы по курсу: ml.cmc@mail.ru

1 Многомерная линейная регрессия

- Метод наименьших квадратов
- Многомерная линейная регрессия
- Сингулярное разложение

2 Проблема мультиколлинеарности и регуляризация

- Проблема мультиколлинеарности
- L_2 -регуляризация: гребневая регрессия
- L_1 -регуляризация и отбор признаков

3 Метод главных компонент

- Постановка задачи и основная теорема
- Метод главных компонент для линейной регрессии
- Обобщения

Оптимизационная постановка задач машинного обучения

X — пространство *объектов*

Y — множество *ответов* (предсказаний / оценок / прогнозов)

$y(x)$, $y: X \rightarrow Y$ — неизвестная зависимость (target function)

Дано: $\{x_1, \dots, x_\ell\} \subset X$ — обучающая выборка (training set)

$a(x, w)$, $a: X \times W \rightarrow Y$ — параметрическая модель зависимости

Найти: $w \in W$ — вектор параметров модели

Критерий — минимум эмпирического риска с регуляризацией:

$$\sum_{i=1}^{\ell} \mathcal{L}(w, x_i) + \tau \mathcal{R}(w) \rightarrow \min_w \quad (\text{empirical risk minimization, ERM})$$

$\mathcal{L}(w, x)$ — *функция потерь* (loss function) — тем больше, чем сильнее $a(x, w)$ отклоняется от правильного ответа $y(x)$,

$\mathcal{R}(w)$ — *регуляризатор* с коэффициентом регуляризации τ

Многомерная линейная регрессия

Дано: $\{x_1, \dots, x_\ell\}$ — обучающая выборка (training set)

$x_i = (f_1(x_i), \dots, f_n(x_i))$ — вектор признаков объекта x_i

$y_i = y(x_i) \in \mathbb{R}$ — «ответ учителя» на обучающем объекте x_i

Найти: параметры $w \in \mathbb{R}^n$ модели линейной регрессии:

$$a(x, w) = \sum_{j=1}^n w_j f_j(x) = \langle w, x \rangle = w^T x, \quad w, x \in \mathbb{R}^n.$$

Матричные обозначения:

$$F = \begin{pmatrix} f_1(x_1) & \dots & f_n(x_1) \\ \dots & \dots & \dots \\ f_1(x_\ell) & \dots & f_n(x_\ell) \end{pmatrix}_{\ell \times n} \quad f_j = \begin{pmatrix} f_j(x_1) \\ \dots \\ f_j(x_\ell) \end{pmatrix}_{\ell \times 1} \quad y = \begin{pmatrix} y_1 \\ \dots \\ y_\ell \end{pmatrix}_{\ell \times 1} \quad w = \begin{pmatrix} w_1 \\ \dots \\ w_n \end{pmatrix}_{n \times 1}$$

Критерий — метод наименьших квадратов (МНК):

$$Q(w, X^\ell) = \sum_{i=1}^{\ell} (a(x_i, w) - y_i)^2 = \|Fw - y\|^2 \rightarrow \min_w$$

Нормальная система уравнений

Необходимое условие минимума в матричном виде:

$$\frac{\partial Q(w)}{\partial w} = 2F^T(Fw - y) = 0,$$

откуда следует *нормальная система* задачи МНК:

$$F^T F w = F^T y,$$

где $F^T F$ — симметричная матрица размера $n \times n$

Допущение: F и $F^T F$ — матрицы полного ранга n и $\ell \geq n$

Решение системы: $w^* = (F^T F)^{-1} F^T y = F^+ y$

Значение критерия: $Q(w^*) = \|P_F y - y\|^2,$

где $P_F = FF^+ = F(F^T F)^{-1} F^T$ — проекционная матрица

Геометрическая интерпретация МНК


Линейная оболочка столбцов матрицы $F = (f_1, \dots, f_n)$, $f_j \in \mathbb{R}^\ell$:

$$\mathcal{L}(F) = \left\{ \sum_{j=1}^n w_j f_j \mid w \in \mathbb{R}^n \right\}$$

$P_F = F(F^T F)^{-1} F^T$ — проекционная матрица

$P_F u$ — проекция вектора $u \in \mathbb{R}^\ell$ на подпространство $\mathcal{L}(F)$

$(I_\ell - P_F)u$ — проекция u на его ортогональное дополнение



МНК — это опускание перпендикуляра в $\mathbb{R}^\ell$ из u на $\mathcal{L}(F)$

Сингулярное разложение

Произвольная $\ell \times n$ -матрица представима в виде *сингулярного разложения* (singular value decomposition, SVD):

$$F = VDU^T.$$

Основные свойства сингулярного разложения:

- 1 $\ell \times n$ -матрица $V = (v_1, \dots, v_n)$ ортогональна, $V^T V = I_n$, столбцы v_j — собственные векторы $\ell \times \ell$ -матрицы FF^T ;
- 2 $n \times n$ -матрица $U = (u_1, \dots, u_n)$ ортогональна, $U^T U = I_n$, столбцы u_j — собственные векторы $n \times n$ -матрицы $F^T F$;
- 3 $n \times n$ -матрица D диагональна, $D = \text{diag}(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_n})$, $\lambda_j \geq 0$ — общие собственные значения матриц $F^T F$ и FF^T .

Решение МНК через сингулярное разложение

Псевдообратная $F^+ = (F^T F)^{-1} F^T$, вектор МНК-решения w^* ,
 МНК-аппроксимация целевого вектора Fw^* и L_2 -норма $\|w^*\|$:

$$F^+ = (UDV^T VDU^T)^{-1} UDV^T = UD^{-1} V^T = \sum_{j=1}^n \frac{1}{\sqrt{\lambda_j}} u_j v_j^T;$$

$$w^* = F^+ y = UD^{-1} V^T y = \sum_{j=1}^n \frac{1}{\sqrt{\lambda_j}} u_j (v_j^T y);$$

$$Fw^* = P_F y = (VDU^T) UD^{-1} V^T y = VV^T y = \sum_{j=1}^n v_j (v_j^T y);$$

$$\|w^*\|^2 = \|UD^{-1} V^T y\|^2 = \|D^{-1} V^T y\|^2 = \sum_{j=1}^n \frac{1}{\lambda_j} (v_j^T y)^2.$$

Тождества: $(AB)^{-1} = B^{-1}A^{-1}$, $(AB)^T = B^T A^T$, $\|w\|^2 = w^T w$

Мультиколлинеарность и переобучение в линейных моделях

Мультиколлинеарность — линейная зависимость признаков:

- пусть построена линейная модель: $a(x, w) = w^T x$
мультиколлинеарность: $\exists u \in \mathbb{R}^n: \forall x \in X \quad u^T x = 0$
неединственность решения: $\forall \gamma \in \mathbb{R} \quad a(x, w) = (w + \gamma u)^T x$
- частный случай: $\ell < n$, недостаточный объём выборки

Проявления мультиколлинеарности:

- $F^T F$ имеет нулевые (или близкие к нулевым) с.з. $\lambda_j \rightarrow 0$
- $F^T F$ имеет большое число обусловленности (см. далее)
- веса w_j^* «разбегаются» — разных знаков, с большими $|w_j^*|$
- веса w_j^* не интерпретируются как важности признаков
- неустойчивость линейной модели $a(x, w) = w^T x$
- $Q(X^\ell) \ll Q(X^k)$ — переобучение

Мультиколлинеарность и число обусловленности матрицы

Число обусловленности $n \times n$ -матрицы S :

$$\mu(S) = \|S\| \|S^{-1}\| = \frac{\max_{u: \|u\|=1} \|Su\|}{\min_{u: \|u\|=1} \|Su\|} = \frac{\lambda_{\max}}{\lambda_{\min}}$$

При умножении обратной матрицы на вектор, $z = S^{-1}u$, относительная погрешность усиливается в $\mu(S)$ раз:

$$\frac{\|\delta z\|}{\|z\|} \leq \mu(S) \frac{\|\delta u\|}{\|u\|}$$

В нашем случае $w^* = (F^T F)^{-1} F^T y = S^{-1}u$, где $S = F^T F$, $u = F^T y$, погрешности измерения $f_j(x_i)$ и y_i усиливаются в $\mu(F^T F)$ раз

Стратегии устранения мультиколлинеарности и переобучения:

- 1 регуляризация: $\|w\| \rightarrow \min$
- 2 отбор признаков: $f_1, \dots, f_n \rightarrow f_{j_1}, \dots, f_{j_m}, \quad m \ll n$
- 3 преобразование признаков: $f_1, \dots, f_n \rightarrow g_1, \dots, g_m, \quad m \ll n$

Гребневая регрессия (ridge regression)

Штраф за увеличение L_2 -нормы вектора весов $\|w\|^2 = \sum_{j=1}^n w_j^2$:

$$Q_\tau(w) = \|Fw - y\|^2 + \frac{\tau}{2} \|w\|^2,$$

где τ — неотрицательный *параметр регуляризации*

Модифицированное МНК-решение (τI_n — «гребень», ridge):

$$\begin{aligned} \frac{\partial Q_\tau(w)}{\partial w} &= 2F^\top(Fw - y) + 2\tau w = 0 \\ w_\tau^* &= (F^\top F + \tau I_n)^{-1} F^\top y \end{aligned}$$

Преимущество сингулярного разложения:

можно подбирать параметр τ , вычислив SVD только один раз

Гребневая регрессия через сингулярное разложение

Вектор регуляризованного МНК-решения w_τ^*
и МНК-аппроксимация целевого вектора Fw_τ^* :

$$w_\tau^* = U(D^2 + \tau I_n)^{-1} D V^T y = \sum_{j=1}^n \frac{\sqrt{\lambda_j}}{\lambda_j + \tau} u_j (v_j^T y)$$

$$Fw_\tau^* = V D U^T w_\tau^* = V \operatorname{diag}\left(\frac{\lambda_j}{\lambda_j + \tau}\right) V^T y = \sum_{j=1}^n \frac{\lambda_j}{\lambda_j + \tau} v_j (v_j^T y)$$

$$\|w_\tau^*\|^2 = \|(D^2 + \tau I_n)^{-1} D V^T y\|^2 = \sum_{j=1}^n \frac{\lambda_j}{(\lambda_j + \tau)^2} (v_j^T y)^2$$

Решение смещённое ($Fw_\tau^* \neq Fw^*$), но зато более устойчивое

Выбор параметра регуляризации τ

Контрольная выборка $X^k = (x'_i, y'_i)_{i=1}^k$

$$F'_{k \times n} = \begin{pmatrix} f_1(x'_1) & \dots & f_n(x'_1) \\ \dots & \dots & \dots \\ f_1(x'_k) & \dots & f_n(x'_k) \end{pmatrix} \quad y'_{k \times 1} = \begin{pmatrix} y'_1 \\ \dots \\ y'_k \end{pmatrix}$$

Вычисление функционала Q на контрольных данных T раз потребует $O(kn^2 + knT)$ операций:

$$Q(w_\tau^*, X^k) = \|F' w_\tau^* - y'\|^2 = \left\| \underbrace{F' U}_{k \times n} \operatorname{diag}\left(\frac{\sqrt{\lambda_j}}{\lambda_j + \tau}\right) \underbrace{V^\top y}_{n \times 1} - y' \right\|^2$$

Зависимость $Q(w_\tau^*, X^k)$ от τ обычно имеет минимум, поскольку

- при $\tau \rightarrow \infty$ регуляризация разрушает модель, $w \rightarrow 0$
- при $\tau \rightarrow 0$ регуляризации нет, возможно переобучение

Регуляризация сокращает «эффективную размерность»

Сжатие (shrinkage) или *сокращение весов* (weight decay):

$$\|w_{\tau}^*\|^2 = \sum_{j=1}^n \frac{\lambda_j}{(\lambda_j + \tau)^2} (v_j^T y)^2 < \|w^*\|^2 = \sum_{j=1}^n \frac{1}{\lambda_j} (v_j^T y)^2.$$

Почему говорят о *сокращении эффективной размерности*?

Роль размерности играет след проекционной матрицы:

$$\text{tr } F(F^T F)^{-1} F^T = \text{tr}(F^T F)^{-1} F^T F = \text{tr } I_n = n.$$

При использовании регуляризации:

$$\text{tr } F(F^T F + \tau I_n)^{-1} F^T = \text{tr } \text{diag} \left(\frac{\lambda_j}{\lambda_j + \tau} \right) = \sum_{j=1}^n \frac{\lambda_j}{\lambda_j + \tau} < n.$$

Тождество: $\text{tr}(AB) = \text{tr}(BA)$


Регуляризация по L_1 -норме для отбора признаков

LASSO — Least Absolute Shrinkage and Selection Operator

$$Q(w) + \mu \sum_{j=1}^n |w_j| \rightarrow \min_w \iff \begin{cases} Q(w) \rightarrow \min_w; \\ \sum_{j=1}^n |w_j| \leq \kappa; \end{cases}$$


LASSO (L_1):

$$\sum_{j=1}^n |w_j| \leq \kappa$$




Ridge (L_2):

$$\sum_{j=1}^n w_j^2 \leq \kappa$$



Сравнение L_2 (Ridge) и L_1 (LASSO) регуляризации


Типичный вид зависимости весов w_j от коэффициента μ



LASSO с увеличением μ усиливает отбор признаков

Геометрическая интерпретация отбора признаков

Сравнение регуляризаторов по различным L_p -нормам:



Негладкость регуляризатора приводит к отбору признаков


Двойной регуляризатор $L_1 + L_2$ (Elastic Net)

$$Q(w) + \mu \sum_{j=1}^n |w_j| + \frac{\tau}{2} \sum_{j=1}^n w_j^2 \rightarrow \min_w$$

- ⊕ Параметр селективности μ управляет отбором признаков: чем больше μ , тем меньше признаков останется
- ⊕ Есть эффект группировки (grouping effect): значимые зависимые признаки отбираются вместе и имеют примерно равные веса w_j
- ⊖ Приходится подбирать два параметра регуляризации μ , τ (есть специальные методы — regularization path)
- ⊖ Шумовые признаки также группируются вместе; по мере увеличения μ группы значимых признаков могут отбрасываться, когда ещё не все шумовые отброшены

Двойной регуляризатор $L_1 + L_2$ (Elastic Net)

Elastic Net менее жёстко отбирает признаки, чем LASSO.
Зависимости весов w_j от коэффициента $\log \frac{1}{\mu}$:




scikit-learn.org/0.5/auto_examples/glm/plot_lasso_coordinate_descent_path.html

Отбор опорных признаков (Support Features Machine, SFM)

Гладкая склейка L_1 и L_2 регуляризаторов:

$$Q(w) + \sum_{j=1}^n R_{\mu}(w_j) \rightarrow \min_w$$
$$R_{\mu}(w_j) = \begin{cases} 2\mu|w_j|, & |w_j| \leq \mu \\ \mu^2 + w_j^2, & |w_j| \geq \mu \end{cases}$$



- ⊕ Только один параметр регуляризации μ
- ⊕ Отбор признаков с *параметром селективности* μ
- ⊕ *Эффект группировки*: значимые зависимые признаки ($|w_j| > \mu$) входят в решение совместно (как в Elastic Net)
- ⊕ Шумовые признаки ($|w_j| < \mu$) не группируются и подавляются независимо друг от друга (как в LASSO)


Tatarchuk A., Urlov E., Mottl V., Windridge D. A support kernel machine for supervised selective combining of diverse pattern-recognition modalities. 2010.

Отбор релевантных признаков (Relevance Feature Machine, RFM)

Невыпуклый регуляризатор:

$$Q(w) + \sum_{j=1}^n \ln(w_j^2 + \frac{1}{\mu}) \rightarrow \min_w$$

$$R(w) = \ln(w^2 + \frac{1}{\mu}) \text{ при } \mu = 0.1, 1, 100$$



- ⊕ Только один параметр регуляризации μ
- ⊕ Отбор признаков с параметром *селективности* μ
- ⊕ Есть эффект группировки
- ⊕ Лучше отбирает набор значимых признаков, когда они только совместно обеспечивают хорошее решение

Tatarchuk A., Mottl V., Eliseyev A., Windridge D. Selectivity supervision in combining pattern recognition modalities by feature- and kernel-selective Support Vector Machines. 2008.

Метод главных компонент (Principal Component Analysis, PCA)

Дано: выборка объектов $\{x_1, \dots, x_\ell\}$;
 $f_1(x), \dots, f_n(x)$ — числовые признаки объектов

Найти:

$g_1(x), \dots, g_m(x)$ — новые числовые признаки, $m \leq n$, и
линейную реконструкцию старых признаков $f_j(x)$ по новым:

$$\hat{f}_j(x) = \sum_{t=1}^m g_t(x) u_{jt}, \quad j = 1, \dots, n, \quad \forall x \in X,$$

Критерий: точность реконструкции f_j на обучающей выборке:

$$Q = \sum_{i=1}^{\ell} \sum_{j=1}^n (\hat{f}_j(x_i) - f_j(x_i))^2 \rightarrow \min_{\{g_t(x_i)\}, \{u_{jt}\}}$$

Задача преобразования признаков (feature transformation)
— это задача обучения без учителя, тут нет ответов y_i

Задача низкорангового матричного разложения

Матрицы «объекты–признаки», старая и новая:

$$F_{\ell \times n} = \begin{pmatrix} f_1(x_1) & \dots & f_n(x_1) \\ \dots & \dots & \dots \\ f_1(x_\ell) & \dots & f_n(x_\ell) \end{pmatrix}; \quad G_{\ell \times m} = \begin{pmatrix} g_1(x_1) & \dots & g_m(x_1) \\ \dots & \dots & \dots \\ g_1(x_\ell) & \dots & g_m(x_\ell) \end{pmatrix}.$$

Матрица линейного преобразования новых признаков в старые:

$$U_{n \times m} = \begin{pmatrix} u_{11} & \dots & u_{1m} \\ \dots & \dots & \dots \\ u_{n1} & \dots & u_{nm} \end{pmatrix}; \quad \hat{F} = GU^T \overset{\text{хотим}}{\approx} F.$$

Критерий в матричном виде — ищем одновременно G и U :

$$Q(G, U) = \sum_{i=1}^{\ell} \sum_{j=1}^n (\hat{f}_j(x_i) - f_j(x_i))^2 = \|GU^T - F\|^2 \rightarrow \min_{G, U},$$

Основная теорема метода главных компонент

Теорема

Если $m \leq \text{rk } F$, то минимум $\|GU^T - F\|^2$ достигается, когда столбцы U — это с.в. матрицы $F^T F$, соответствующие m максимальным с.з. $\lambda_1, \dots, \lambda_m$, а матрица $G = FU$.

При этом:

- ❶ матрица U ортонормирована: $U^T U = I_m$;
- ❷ матрица G ортогональна: $G^T G = \Lambda = \text{diag}(\lambda_1, \dots, \lambda_m)$;
- ❸ $U\Lambda = F^T F U$; $G\Lambda = FF^T G$;
- ❹ $\|GU^T - F\|^2 = \|F\|^2 - \text{tr } \Lambda = \sum_{j=m+1}^n \lambda_j$.

Тождество: $\|F\|^2 = \text{tr}(F^T F) = \sum_{j=1}^n \lambda_j$

Связь с сингулярным разложением

Произвольная $\ell \times n$ -матрица F представима в виде SVD:

$$F = VDU^T; \quad U^T U = I_m; \quad V^T V = I_m; \quad D = \text{diag}(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_n})$$

Если взять $m = n$, то:

- 1 $\|GU^T - F\|^2 = 0$
- 2 представление $\hat{F} = GU^T = F$ точное и совпадает с SVD, если положить $G = V\sqrt{\Lambda}$, $D = \sqrt{\Lambda}$:

$$F = GU^T = V\sqrt{\Lambda}U^T;$$

- 3 линейное преобразование U работает в обе стороны:

$$F = GU^T; \quad G = FU.$$

$G^T G = \Lambda$ — новые признаки некоррелированы,

U — декоррелирующее преобразование Карунена–Лозва


Эффективная размерность выборки

Упорядочим с.з. $F^T F$ по убыванию: $\lambda_1 \geq \dots \geq \lambda_n \geq 0$.

Эффективная размерность выборки — это наименьшее целое m , при котором

$$E_m = \frac{\|GU^T - F\|^2}{\|F\|^2} = \frac{\lambda_{m+1} + \dots + \lambda_n}{\lambda_1 + \dots + \lambda_n} \leq \varepsilon.$$

Критерий «крутого склона»: находим m : $E_{m-1} \gg E_m$:



Решение задачи НК в новых признаках

Заменим $F_{\ell \cdot n}$ на её приближение $G_{\ell \cdot m} \cdot U_{m \cdot n}^T$, предполагая $m \leq n$:

$$\|G \underbrace{U^T w}_{z} - y\|^2 = \|Gz - y\|^2 \rightarrow \min_z.$$

Связь нового и старого вектора коэффициентов:

$$z = U^T w; \quad w = Uz.$$

Решение задачи наименьших квадратов относительно z :

$$z^* = D^{-1} V^T y; \quad w^* = U D^{-1} V^T y = \sum_{j=1}^m \frac{1}{\sqrt{\lambda_j}} u_j (v_j^T y);$$

$$Gz^* = V V^T y = \sum_{j=1}^m v_j (v_j^T y);$$

Единственное отличие от прежнего w^* — m слагаемых вместо n

Спектральный метод наименьших квадратов

1. Построить SVD-разложение, упорядочить $\lambda_1 \geq \dots \geq \lambda_n$
2. Отделить $n - m$ наименьших с.з. от нуля: $\lambda'_j := \lambda_j + \delta_j$

Частные случаи:

- $\lambda'_j := \lambda_j + \tau$ — гребневая регрессия
- $\lambda'_j := \lambda_j + \infty[j > m]$ — метод главных компонент
- $\lambda'_j := \lambda_j + \tau[j > m]$ — нечто промежуточное

3. Применить формулы SVD для модификации МНК-решения:

$$w^* = \sum_{j=1}^n \frac{1}{\sqrt{\lambda_j}} u_j(v_j^T y) \quad \longrightarrow \quad w^* = \sum_{j=1}^n \frac{\sqrt{\lambda_j}}{\lambda'_j} u_j(v_j^T y)$$

$$Fw^* = \sum_{j=1}^n v_j(v_j^T y) \quad \longrightarrow \quad Fw^* = \sum_{j=1}^n \frac{\lambda_j}{\lambda'_j} v_j(v_j^T y)$$

Разреженное низкоранговое матричное разложение

Дано: матрица $F = (f_{ij})_{\ell \times n}$, $(i, j) \in \Omega \subseteq \{1, \dots, \ell\} \times \{1, \dots, n\}$

Найти: матрицы $G = (g_{it})_{\ell \times m}$ и $U^T = (u_{tj})_{m \times n}$

Критерий: $\|F - GU^T\|_{\Omega}^2 = \sum_{(i,j) \in \Omega} \left(f_{ij} - \sum_t g_{it} u_{tj} \right)^2 \rightarrow \min_{G, U}$

Классический SVD становится неприменим, когда

- данные разреженные: $|\Omega| < \ell n$, часто $|\Omega| \ll \ell n$
- функция потерь неквадратичная
- матричное разложение неотрицательное: $g_{it} \geq 0$, $u_{tj} \geq 0$
или стохастическое: $\sum_t g_{it} = 1$, $\sum_t u_{tj} = 1$, $g_{it} \geq 0$, $u_{tj} \geq 0$

Ситуации применения:

- снижение размерности вектора признаков, $m \ll n$
- выявление латентной внутренней структуры данных
- восстановление пропущенных значений (missing values)

Примеры прикладных задач матричного разложения

- 1 Выявление интересов в рекомендательных системах (recommender systems, collaborative filtering)

$$z_{iu} = \sum_t p_{it} q_{tu}$$

дано: z_{iu} — рейтинги товаров i , поставленные пользователем u ;

найти: p_{it} — профиль интересов товара i ;

q_{tu} — профиль интересов пользователя u .

- 2 Разделение смеси химических веществ по данным жидкостной хроматографии

$$z_{t\lambda} = \sum_i x_{ti} y_{i\lambda}$$

дано: $z_{t\lambda}$ — выход сканирующего УФ-детектора;

найти: x_{ti} — хроматограмма i -го вещества, t — время;

$y_{i\lambda}$ — спектр i -го вещества, λ — длина волны.

Примеры прикладных задач матричного разложения

- 3 Латентный семантический анализ коллекций текстов
(тематическое моделирование)

$$z_{wd} = \sum_t \varphi_{wt} \theta_{td}$$

дано: $z_{wd} = p(w|d)$ — частоты слов w в документах d ;

найти: $\varphi_{wt} = p(w|t)$ — распределения слов w в темах t ,

$\theta_{td} = p(t|d)$ — распределения тем t в документах d .

- 4 Оценивание экспрессии генов по данным
ДНК-микрочипов с учётом кросс-гибридизации

$$z_{pk} = \sum_g a_{pg} c_{gk}$$

дано: z_{pk} — интенсивность свечения p -й пробы на k -м чипе;

найти: a_{pg} — коэффициент сродства p -й пробы g -му гену,

c_{gk} — концентрация g -го гена на k -м чипе.

- Многомерная линейная регрессия
— через *сингулярное разложение*
- Три приёма против мультиколлинеарности и переобучения
— регуляризация, отбор и преобразование признаков
- L_2 -регуляризация, она же гребневая регрессия
— тоже через *сингулярное разложение*
- L_1 -регуляризация (LASSO) и др. негладкие регуляризаторы
— регулируемый отбор признаков
- Метод главных компонент — задача матричного разложения
— снова через *сингулярное разложение*
- Другие методы матричных разложений и их приложения
— в следующем семестре