

Методы машинного обучения

Метод стохастического градиента и линейные модели классификации

Воронцов Константин Вячеславович

www.MachineLearning.ru/wiki?title=User:Vokov

вопросы к лектору: vorontsovkv@my.msu.ru

материалы курса:

github.com/MSU-ML-COURSE/ML-COURSE-26-27

орг.вопросы по курсу: ml.cmc@mail.ru

1 Градиентная оптимизация в машинном обучении

- Оптимизационные задачи в машинном обучении
- Метод стохастического градиента
- Ускорение сходимости и другие эвристики

2 Модели классификации на основе разделимости

- Разделяющие модели классификации
- Линейные модели классификации
- Регуляризация линейных моделей

3 Искусственные нейронные сети

- Аппроксимационные возможности нейронных сетей
- Многослойные нейронные сети
- История искусственных нейронных сетей

Общая постановка задачи обучения по прецедентам

Дано: X — пространство объектов

$X^\ell = \{x_1, \dots, x_\ell\} \subset X$ — обучающая выборка, прецеденты

$a(x, w)$, $a: X \times W \rightarrow Y$ — параметрическая модель, гипотеза

Найти $w \in W$ — вектор параметров модели $a(x, w)$

Критерий Empirical Risk Minimization (ERM) — минимизация эмпирического риска, в общем случае с регуляризацией:

$$Q(w) = \frac{1}{\ell} \sum_{i=1}^{\ell} \mathcal{L}(w, x_i) + \tau \mathcal{R}(w) \rightarrow \min_w$$

$\mathcal{L}(w, x)$ — функция потерь (loss function),

тем больше, чем хуже ответ модели $a(x, w)$ на объекте x

$\mathcal{R}(w)$ — регуляризатор, априорные требования к модели

τ — коэффициент регуляризации для балансировки критериев

Градиентный метод минимизации эмпирического риска

$$Q(w) = \frac{1}{\ell} \sum_{i=1}^{\ell} \mathcal{L}(w, x_i) + \tau \mathcal{R}(w) \rightarrow \min_w$$

Метод градиентного спуска:

$w^{(0)}$:= начальное приближение;


$$w^{(t+1)} := w^{(t)} - h \nabla_w Q(w^{(t)})$$

где $\nabla_w Q(w) = \left(\frac{\partial Q(w)}{\partial w_j} \right)_{j=1}^N$ — вектор градиента,

h — градиентный шаг, называемый также темпом обучения

$$w^{(t+1)} := w^{(t)} - h \left(\frac{1}{\ell} \sum_{i=1}^{\ell} \nabla_w \mathcal{L}(w^{(t)}, x_i) + \tau \nabla_w \mathcal{R}(w^{(t)}) \right)$$

Идея ускорения сходимости: брать случайное подмножество слагаемых, или даже один объект, сразу обновляя вектор весов



Метод стохастического градиента SG (Stochastic Gradient)

$$\text{Критерий ERM: } Q(w) = \frac{1}{\ell} \sum_{i=1}^{\ell} \mathcal{L}(w, x_i) + \tau \mathcal{R}(w) \rightarrow \min_w$$

Вход: выборка X^ℓ , параметры h, τ, λ ;

Выход: вектор весов w ;

- 1 инициализировать веса $w_j, j = 1, \dots, N$;
- 2 инициализировать оценку $Q(w)$ по небольшой подвыборке;
- 3 **повторять**
 - 4 объект x_i выбрать из X^ℓ случайным образом;
 - 5 потеря: $\mathcal{L}_i := \mathcal{L}(w, x_i)$;
 - 6 градиентный шаг: $w := w - h \nabla \mathcal{L}(w, x_i) - h\tau \nabla \mathcal{R}(w)$;
 - 7 рекуррентная оценка критерия: $Q := \lambda \mathcal{L}_i + (1 - \lambda)Q$;
- 8 **пока** значение Q и/или веса w не сойдутся;

H. Robbins, S. Monro. A stochastic approximation method. 1951.

Откуда взялась такая рекуррентная оценка функционала?

Проблема: вычисление оценки Q по всей выборке $x_1, \dots, x_\ell$ намного дольше градиентного шага по одному объекту x_i .

Решение: использовать приближённую рекуррентную формулу.

Среднее арифметическое:

$$\bar{Q}_m = \frac{1}{m} \mathcal{L}_m + \frac{1}{m} \mathcal{L}_{m-1} + \frac{1}{m} \mathcal{L}_{m-2} + \dots$$

$$\bar{Q}_m = \frac{1}{m} \mathcal{L}_m + (1 - \frac{1}{m}) \bar{Q}_{m-1}$$

Экспоненциальное скользящее среднее (ЭСС):

$$\bar{Q}_m = \lambda \mathcal{L}_m + (1 - \lambda) \lambda \mathcal{L}_{m-1} + (1 - \lambda)^2 \lambda \mathcal{L}_{m-2} + \dots$$

$$\bar{Q}_m = \lambda \mathcal{L}_m + (1 - \lambda) \bar{Q}_{m-1}$$


Параметр λ (порядка $\frac{1}{m}$) — *темп забывания* предыстории ряда.

Метод накопления инерции (momentum)

Momentum — экспоненциальное скользящее среднее градиента по последним $\approx \frac{1}{1-\gamma}$ итерациям [Б.Т.Поляк, 1964]:

$$v := \gamma v + (1-\gamma) \nabla \mathcal{L}(w, x_i)$$



$$w := w - hv$$



NAG (Nesterov's accelerated gradient) — стохастический градиент с инерцией [Ю.Е.Нестеров, 1983]:

$$v := \gamma v + (1-\gamma) \nabla \mathcal{L}(w - h\gamma v, x_i)$$

$$w := w - hv$$



Эвристики

- ❶ инициализация параметров w :
случайная, по корреляции, комбинированная, ...
- ❷ порядок предъявления объектов:
чем больше $\mathcal{L}_i$, тем выше вероятность выбрать x_i
- ❸ выбор градиентного шага: *метод скорейшего спуска*
основан на поиске оптимального *адаптивного шага* h^* :

$$\mathcal{L}(w - h\nabla\mathcal{L}(w, x_i), x_i) \rightarrow \min_h$$

- ❹ мультистарт: многократные запуски из разных случайных начальных приближений и выбор лучшего решения
- ❺ метод Ньютона-Рафсона (второго порядка сходимости):

$w := w - h(\mathcal{L}''(w, x_i))^{-1}\nabla\mathcal{L}(w, x_i)$, $\mathcal{L}''$ — матрица Гессе
(в частности, диагональный метод Левенберга-Марквардта)

Диагональный метод Левенберга-Марквардта

Метод Ньютона-Рафсона:

$$w := w - h (\mathcal{L}''(w, x_i))^{-1} \nabla \mathcal{L}(w, x_i),$$

где $\mathcal{L}''(w, x_i) = \left(\frac{\partial^2 \mathcal{L}(w, x_i)}{\partial w_j \partial w_{j'}} \right)$ — гессиан, $n \times n$ -матрица

Эвристика. Считаем, что гессиан диагонален:

$$w_j := w_j - h \max \left\{ \mu, \frac{\partial^2 \mathcal{L}(w, x_i)}{\partial w_j^2} \right\}^{-1} \frac{\partial \mathcal{L}(w, x_i)}{\partial w_j},$$

$h > 0$ — темп обучения, можно полагать $h = 1$,

$\mu > 0$ — параметр, предотвращающий обнуление знаменателя.

Вблизи минимума сходимость второго порядка с темпом h

Вдали от минимума сходимость первого порядка с темпом $\frac{h}{\mu}$

Метод SG: достоинства и недостатки

Достоинства:

- *простота*: относительно легко реализуется
- *универсальность*: для любых $a(x, w)$, $\mathcal{L}(w, x)$, $\mathcal{R}(w)$
- *поточность*: возможность обучения на потоке данных
- *подходит для обработки больших данных*:
 - можно получить неплохое решение, успев обработать лишь малую часть обучающей выборки
 - часто оказывается быстрее и лучше более сложных и ресурсоёмких методов второго порядка

Недостатки:

- подбор комплекса эвристик является искусством
(не забыть про переобучение, застревание, расходимость)

Задача бинарной классификации


Дано: обучающая выборка $(x_i, y_i)_{i=1}^{\ell}$, $y_i \in \{-1, +1\}$

Найти: вектор w модели классификации $a(x, w) = \text{sign } b(x, w)$

Критерий: $\min$ аппроксимированного эмпирического риска

$$\sum_{i=1}^{\ell} [b(x_i, w)y_i < 0] \leq Q(w) = \sum_{i=1}^{\ell} L(b(x_i, w)y_i) \rightarrow \min_w$$


Убывающие функции потерь $L(M)$ от отступа $M = b(x, w)y(x)$:



Каждая из этих функций придаёт модели особые свойства

Непрерывные аппроксимации пороговой функции потерь

Выбор функции потерь $L(M)$ порождает большое разнообразие методов, отличающихся полезными свойствами (это спойлер)



$[M < 0]$

$$V = (1 - M)_+$$

$$H = (-M)_+$$

$$L = \log_2(1 + e^{-M})$$

$$Q = (1 - M)^2$$

$$S = 2(1 + e^M)^{-1}$$

$$E = e^{-M}$$

пороговая функция потерь

кусочно-линейная (метод опорных векторов, SVM)

кусочно-линейная (правило Хэбба, Hebb's rule)

логарифмическая (логистическая регрессия, LR)

квадратичная (линейный дискриминант Фишера, FLD)

сигмоидная (искусственные нейронные сети, ANN)

экспоненциальная (линейный ансамбль AdaBoost)

Бинарный разделяющий классификатор (margin-based classifier)

Бинарный классификатор: $a(x, w) = \text{sign } b(x, w)$, $Y = \{-1, +1\}$


$b(x, w)$ — разделяющая (дискриминантная) функция

$\{x: b(x, w) = 0\}$ — разделяющая поверхность между классами

$M_i(w) = b(x_i, w)y_i$ — отступ (margin) объекта x_i

$M_i(w) < 0 \iff$ модель $a(x, w)$ ошибается на x_i

Ранжирование объектов по возрастанию отступов $M_i(w)$:



Задача многоклассовой классификации (multiclass classification)

Дано: обучающая выборка $(x_i, y_i)_{i=1}^{\ell}$, $y_i = y(x_i) \in Y$, $|Y| < \infty$

Найти: вектор $w = (w_y : y \in Y)$ модели классификации

$$a(x, w) = \arg \max_{y \in Y} b_y(x, w_y)$$

где $b_y(x, w_y)$ отделяет объекты класса y от всех остальных,
 $M_{iy}(w) = b_{y_i}(x_i, w_{y_i}) - b_y(x_i, w_y)$ — отступ объекта x_i по классу y

Критерий ERM «каждый против всех» (one-vs.-all, OvA):

$$\sum_{i=1}^{\ell} \sum_{y \neq y_i} [M_{iy}(w) < 0] \leq Q(w) = \sum_{i=1}^{\ell} \sum_{y \neq y_i} L(M_{iy}(w)) \rightarrow \min_w,$$

где функция $L(M)$ выбирается, как правило, невозрастающей

Линейный классификатор — математическая модель нейрона



Модель МакКаллока-Питтса [1943], персептрон Розенблатта [1957]:

$$a(x, w) = \sigma \left(\sum_{j=1}^n w_j f_j(x) - w_0 \right) = \sigma(\langle w, x \rangle - w_0),$$

$\sigma(z)$ — функция активации (например, sign, th или $\frac{1}{1+e^{-z}}$),

w_j — весовые коэффициенты синаптических связей,

w_0 — порог активации, он же вес признака $f_0(x) \equiv -1$



Напоминание. Мультиколлинеарность в линейных моделях

$a(x, w) = \langle w, x \rangle$ — линейная модель регрессии

$a(x, w) = \text{sign} \langle w, x \rangle$ — линейный бинарный классификатор

Мультиколлинеарность — линейная зависимость признаков:

- $\exists u \in \mathbb{R}^n: \forall x \in X \quad \langle u, x \rangle = 0$
- неединственность решения: $\forall \gamma \in \mathbb{R} \quad \langle w, x \rangle = \langle w + \gamma u, x \rangle$

Мультиколлинеарность приводит к переобучению:

- неустойчивость: слишком большие веса $|w_j|$ разных знаков
- переобучение: $Q(w^*, X^\ell) \ll Q(w^*, X^k)$

Как уменьшить переобучение:

- регуляризация $\|w\| \rightarrow \min$ (сокращение весов, weight decay)
- отбор признаков: $f_1, \dots, f_n \rightarrow f_{j_1}, \dots, f_{j_m}, \quad m \ll n$
- преобразование признаков: $f_1, \dots, f_n \rightarrow g_1, \dots, g_m, \quad m \ll n$

Регуляризация по L_2 -норме (сокращение весов, weight decay)

Критерий со штрафом за увеличение нормы вектора весов:

$$Q_\tau(w) = Q(w) + \frac{\tau}{2} \|w\|^2 = \frac{1}{\ell} \sum_{i=1}^{\ell} \mathcal{L}(w, x_i) + \frac{\tau}{2} \sum_{j=1}^n w_j^2 \rightarrow \min_w$$

Градиент функции потерь в методе SG:

$$\nabla \mathcal{L}(w, x_i) + \tau w$$

Модификация градиентного шага в методе SG:

$$w := w(1 - \tau h) - h \nabla \mathcal{L}(w, x_i).$$

Методы подбора коэффициента регуляризации τ :

- hold-out или скользящий контроль
- стохастическая адаптация: чаще выбираем такие значения из сетки $\{\tau_k\}$, которые в среднем быстрее ведут к успеху

Напоминание. Негладкие регуляризаторы для отбора признаков

Общий вид регуляризаторов (τ — параметр селективности):

$$\sum_{i=1}^{\ell} \mathcal{L}(w, x_i) + \sum_{j=1}^n R_{\tau}(w_j) \rightarrow \min_w$$

LASSO (L_1): $R_{\tau}(w) = \tau|w|$

— отбрасывает мультиколлинеарные признаки

Elastic Net: $R_{\tau}(w) = \tau|w| + \lambda w^2$

— группирует совместно значимые признаки

Support Feature Machine (SFM):



$$R_{\tau}(w) = [|w| \leq \tau] \cdot 2\tau|w| + [|w| > \tau] \cdot (\tau^2 + w^2)$$

— группирует, отбрасывая незначимые признаки

Relevance Feature Machine (RFM):







$$R_{\tau}(w) = \ln(\tau w^2 + 1)$$

— точнее находит совместно значимые признаки



Реализация булевых функций линейным нейроном

Функции И, ИЛИ, НЕ бинарных признаков x^1, x^2 :




Дизъюнктивная нормальная форма $\iff$ двухслойная нейросеть
 позволяет реализовать любую булеву функцию n переменных


Ограничение линейных моделей: функция XOR

Функция $x^1 \oplus x^2 = [x^1 \neq x^2]$ не реализуема одним нейроном.
 Два способа реализации:


- Добавлением нелинейного признака (feature generation):
 $x^1 \oplus x^2 = [x^1 + x^2 - 2x^1x^2 - \frac{1}{2} > 0]$;
- Сетью** (двухслойной суперпозицией) функций И, ИЛИ, НЕ:
 $x^1 \oplus x^2 = [(x^1 \vee x^2) - (x^1 \wedge x^2) - \frac{1}{2} > 0]$.



1-й способ



2-й способ




Персептрон Розенблатта (1957)

Mark-1 — первый нейрокомпьютер (1960)

для распознавания цифр и фигур

Обучение — метод коррекции ошибки

Архитектура — двухслойная сеть



Фрэнк Розенблатт
(1928–1971)



Розенблатт Ф. Принципы нейродинамики. Перцептроны и теория механизмов мозга. 1965 (1962)

Любую ли функцию можно представить нейросетью?

Решение тринадцатой (из 23) проблем Гильберта (1900):

Теорема [Колмогоров, 1956; Арнольд, 1957]

Любая непрерывная функция n аргументов на единичном кубе $[0, 1]^n$ представима в виде суперпозиции непрерывных функций одного аргумента и операции сложения:

$$f(x_1, \dots, x_n) = \sum_{k=1}^{2n+1} \Phi_k \left(\sum_{j=1}^n \varphi_{jk}(x_j) \right),$$

где Φ_k, φ_{jk} — непрерывные функции, и φ_{jk} не зависят от f .

Имеет ли теорема Колмогорова отношение к нейросетям?

А.Н.Колмогоров. О представлении непрерывных функций нескольких переменных суперпозициями непрерывных функций меньшего числа переменных. 1956.

В.И.Арнольд. О функции трех переменных. 1957.

Имеет ли теорема Колмогорова отношение к нейросетям?

Вроде да:

- структура суперпозиции соответствует двухслойной сети
- имеются универсальные аппроксимационные свойства

На самом деле — нет:

- это точное представление; нам достаточно аппроксимации
- функции Φ_k , φ_{jk} не гладкие и сложно строятся
- нет ни весов W , ни оптимизационной задачи обучения
- число слоёв 2 и число нейронов $[n, 2n + 1]$ фиксированы

Но можно обобщить конструкцию эвристически (KAN):

- любое число слоёв, любая ширина слоёв
- вместо функций Φ_k , φ_{jk} — одномерные сплайны (с весами)
- использовать стандартные методы обучения (BackProp)

Двухслойные сети — универсальные аппроксиматоры функций

Функция $\sigma(z)$ — *сигмоида*, если $\lim_{z \rightarrow -\infty} \sigma(z) = 0$ и $\lim_{z \rightarrow +\infty} \sigma(z) = 1$.

Теорема Цыбенко (universal approximation theorem, 1989)

Если $\sigma(z)$ — непрерывная сигмоида, то для любой непрерывной на $[0, 1]^n$ функции $f(x)$ существуют такие значения параметров H , $\alpha_h \in \mathbb{R}$, $w_h \in \mathbb{R}^n$, $w_0 \in \mathbb{R}$, что двухслойная сеть

$$a(x) = \sum_{h=1}^H \alpha_h \sigma(\langle x, w_h \rangle - w_0)$$

равномерно приближает $f(x)$ с любой точностью ε :

$$|a(x) - f(x)| < \varepsilon, \text{ для всех } x \in [0, 1]^n.$$


George Cybenko. Approximation by Superpositions of a Sigmoidal function.
Mathematics of Control, Signals, and Systems. 1989.

Нелинейные функции активации


Функции $\sigma(y) = \frac{1}{1+e^{-y}}$ и $\text{th}(y) = \frac{e^y - e^{-y}}{e^y + e^{-y}}$ могут приводить к затуханию градиентов или «параличу сети»

Функция положительной срезки (rectified linear unit, ReLU)


$$\text{ReLU}(y) = \max\{0, y\}; \quad \text{PReLU}(y) = \max\{0, y\} + \alpha \min\{0, y\}$$




Sigmoid




tanh




softplus



ReLU



PReLU



MaxOut

Многослойный персептрон (Multilayer Perceptron, MLP)


Полносвязная сеть, H_l — число нейронов в слое $l = 1, \dots, L$

$x^0 = x = (f_j(x))_{j=0}^n$ — вектор признаков на входе сети, $H_0 = n$


На выходе слоя — новое векторное представление объекта:

$$x^l = \sigma^l(W^l x^{l-1}) \quad \text{или} \quad x_h^l = \sigma_h^l \left(\sum_{k=0}^{H_{l-1}} w_{kh}^l x_k^{l-1} \right), \quad h = 1, \dots, H_l,$$

где $W^l = (w_{kh}^l)$ — матрица весов размера $(H_{l-1}+1) \times H_l$




Зоопарк архитектур нейронных сетей



- *Архитектура сети* — структура слоёв и связей между ними, позволяющая наделять сеть нужными свойствами
- Универсальный метод обучения — BackPropagation: это SG + быстрое вычисление градиента + эвристики

Основные вехи развития нейронных сетей (AI winters)



Иváхненко А. Г., Лапа В. Г. Кибернетические предсказывающие устройства. 1965

Минский М., Пайперт С. Персептроны. 1971 (1969)

Галушкин А. И. Синтез многослойных систем распознавания образов. 1974


Rumelhart D. et al. Learning internal representations by error propagation. 1986

Krizhevsky A. et al. ImageNet classification with deep convolutional neural networks. 2012

Vaswani A. et al. Attention is all you need. 2017

Глубокие свёрточные сети для классификации изображений


IMAGENET



Старт в 2009. Человеческий уровень ошибок 5% пройден в 2015

AlexNet: сеть с обучаемой векторизацией изображений

- + ReLU + Dropout
- + 62M параметров
- + подбор размеров слоёв
- + пополнение выборки
- + GPU




A.Krizhevsky et al. ImageNet classification with deep convolutional neural networks. 2012.

Аппроксимационная способность: глубина важнее ширины

A_{LH}^n — семейство полносвязных многослойных сетей $a(x, w)$:
 n признаков, L слоёв, H нейронов в каждом слое, $x \in \mathbb{R}^n$,
 функции активации кусочно-линейные: ReLU, hard-tanh и т.п.

Мера разнообразия семейства A_{LH}^n — максимальное число
 участков линейности $a(x, w)$ — выпуклых многогранников в $\mathbb{R}^n$.

Пример. Участки линейности, $n = 2$, $L = 3$, $H = 4$:



Теорема. Разнообразие семейства A_{LH}^n растёт как $O(H^{nL})$.

M. Raghu et al. On the Expressive Power of Deep Neural Networks, 2016.

Резюме в конце лекции

- *Метод стохастического градиента (SG, SGD)*
 - общий подход к задачам машинного обучения
 - подходит для обучения по большим данным
 - лежит в основе BackPropagation для обучения ANN, DL
- *Аппроксимация пороговой функции потерь $L(M)$*
 - общий подход к обучению моделей классификации
 - увеличивая зазор, повышает надёжность классификации
- *Регуляризация* снижает переобучение, возникающее в линейных моделях из-за мультиколлинеарности
- *Искусственная нейронная сеть (ANN)* — суперпозиция линейных моделей с нелинейными активациями
- *Глубокое обучение (DL)* — скорее обучаемый векторизатор данных, чем модель работы мозга