

Методы машинного обучения (ММО)

Метрические методы классификации и регрессии

Воронцов Константин Вячеславович

www.MachineLearning.ru/wiki?title=User:Vokov

вопросы к лектору: vorontsovkv@my.msu.ru

материалы курса:

github.com/MSU-ML-COURSE/ML-COURSE-26-27

орг.вопросы по курсу: ml.cmc@mail.ru

1 Введение расстояний между объектами

- Гипотезы компактности или непрерывности
- Функции расстояния между векторами признаков
- Беспознаковые способы вычисления расстояний

2 Метрические методы классификации

- Обобщённый метрический классификатор
- Обобщающая способность метода ближайшего соседа
- Задача отбора эталонных объектов

3 (Непара)метрические методы регрессии

- Ядерное сглаживание (kernel smoothing)
- Обоснование ядерного сглаживания
- Выбор ядра и ширины окна

Гипотезы непрерывности и компактности

Задачи классификации и регрессии:

X — объекты, Y — ответы;

$X^\ell = (x_i, y_i)_{i=1}^\ell$ — обучающая выборка;

Гипотеза непрерывности (для регрессии):

близким объектам соответствуют близкие ответы.

выполнена:




не выполнена:




Гипотеза «компактности» (для классификации):

близкие объекты, как правило, лежат в одном классе.

выполнена:




не выполнена:



Пример: задача классификации цветков ириса [Фишер, 1936]

Классы — компактные сгустки точек (3 класса по 50 объектов)



Формализация понятия «расстояние» (distance)

Евклидова метрика и обобщённая метрика Минковского:

$$\rho(x, x_i) = \left(\sum_{j=1}^n |x^j - x_i^j|^2 \right)^{1/2} \quad \rho(x, x_i) = \left(\sum_{j=1}^n w_j |x^j - x_i^j|^p \right)^{1/p}$$

$x = (x^1, \dots, x^n)$ — вектор признаков объекта x


$x_i = (x_i^1, \dots, x_i^n)$ — вектор признаков объекта x_i

w_j — веса признаков (возможно, обучаемые) играют две роли:

— нормировка, приведение к общему масштабу

— подавление неинформативных (мешающих) признаков

Линии уровня (эквидистантные поверхности) при различных p :




Расстояния между строками / сигналами

Для строк — редакторское расстояние Левенштейна:

СТGGGCTAAAAGGTCCTTAGCC...TTTAGAAAAA.GGGCCATTAGGAAATTGC
СТGGGACTAAA...CCTTAGCCTATTTACAAAAATGGGCCATTAGG...TTGC


Для сигналов — энергия сжатий и растяжений:



В.В.Моттль, О.С.Середин, В.В.Сулимова. Потенциальные функции для беспризнакового восстановления зависимостей на множествах сигналов и символьных последовательностей. Искусственный интеллект. 2004.

Расстояния между изображениями

Расстояние между изображениями на основе выравнивания:



Оценивается энергия растяжения прямоугольной сетки

V.Mottl, A.Kopylov, A.Kostin, A.Yermakov, J.Kittler. Elastic transformation of the image pixel grid for similarity based face identification. ICPR-2002

Задача обучения метрического классификатора

Дано: $X^\ell = (x_i, y_i)_{i=1}^\ell$ — обучающая выборка, $|Y| < \infty$

Найти: метрический классификатор, относящий объект x к тому классу, которому принадлежат его ближайшие соседи:

$$a(x; X^\ell) = \arg \max_{y \in Y} \underbrace{\sum_{i=1}^{\ell} [y_i = y] S(x, x_i)}_{\Gamma_y(x)},$$

$S(x, x_i)$ — функция близости (similarity) пары объектов x и x_i ;
 $\Gamma_y(x)$ — оценка близости объекта x к объектам класса y

Критерий: минимум эмпирического риска

$x^{(r)}$ — r -й сосед объекта x в ранжированной выборке X^ℓ :

$$\rho(x, x^{(1)}) \leq \rho(x, x^{(2)}) \leq \dots \leq \rho(x, x^{(\ell)})$$

$r(x, x_i)$ — ранг соседа $x_i = x^{(r)}$ для объекта x

Варианты параметризации функции близости

$S(x, x_i) = [r(x, x_i) = 1]$ — метод ближайшего соседа (1NN)

$S(x, x_i) = [r(x, x_i) \leq k]$ — метод k ближайших соседей (k NN)

$S(x, x_i) = [r(x, x_i) \leq k]w_i$ — метод взвешенных k NN

$S(x, x_i) = K\left(\frac{1}{h}\rho(x, x_i)\right)$ — метод окна Парзена (Parzen Window),
 $K(z)$ — ядро (kernel), не возрастает и положительно на $[0, 1]$
 h — фиксированная ширина окна (bandwidth)


$S(x, x_i) = K\left(\frac{1}{h(x)}\rho(x, x_i)\right)$ — метод окна Парзена с переменной
шириной окна, $h(x) = \rho(x, x^{(k+1)})$ — по k ближайшим соседям

$S(x, x_i) = \alpha_i K\left(\frac{1}{h_i}\rho(x, x_i)\right)$ — метод потенциальных функций,
каждому x_i соответствуют два обучаемых параметра:

α_i — вес или «сила» потенциала с центром в точке x_i

h_i — «радиус действия» потенциала с центром в точке x_i

Часто используемые ядра $K(z)$



- $P(z) = [|z| \leq 1]$ — прямоугольное
- $T(z) = (1 - |z|) [|z| \leq 1]$ — треугольное
- $E(z) = (1 - z^2) [|z| \leq 1]$ — квадратичное
- $Q(z) = (1 - z^2)^2 [|z| \leq 1]$ — четвертичное
- $G(z) = \exp(-2z^2)$ — гауссовское — нефинитное ядро
- } — финитные ядра

Научная школа М. А. Айзермана

- *Гипотеза компактности*: схожие объекты, как правило, находятся в одном классе
- Идея метода *потенциальных функций* заимствуется из физики (электростатики)
- Линейная модель классификации с ℓ признаками $f_j(x) = K(\frac{1}{h_j}\rho(x, x_j))$:

$$a(x; X^\ell) = \arg \max_{y \in Y} \sum_{j=1}^{\ell} [y_j = y] \alpha_j f_j(x),$$

где α_j, h_j — обучаемые параметры модели, $j = 1, \dots, \ell$



Марк
Аронович
Айзерман
(1913–1992)

Айзерман М. А., Браверман Э. М., Розоноэр Л. И. Теоретические основы метода потенциальных функций в задаче об обучении автоматов разделению входных ситуаций на классы. 1964.

Айзерман М. А., Браверман Э. М., Розоноэр Л. И. Метод потенциальных функций в теории обучения машин. 1970.

Аркадьев А. Г., Браверман Э. М. Обучение машин распознаванию образов. 1964.

Влияние ширины окна h на вид разделяющей поверхности


Пример: $x_i \in \mathbb{R}^2$, $y_i \in \{-1, +1\}$, гауссовское $K(z) = \exp(-2z^2)$

$$a(x) = \arg \max_{y \in Y} \Gamma_y(x) = \text{sign} \left(\underbrace{\Gamma_{+1}(x) - \Gamma_{-1}(x)} \right)$$

ширина окна: $h = 0.05$

чем меньше ширина окна h ,
тем сложнее форма границы,
возможно переобучение

чем больше ширина окна h ,
тем проще форма границы,
возможно недообучение



Влияние ширины окна h на вид разделяющей поверхности


Пример: $x_i \in \mathbb{R}^2$, $y_i \in \{-1, +1\}$, гауссовское $K(z) = \exp(-2z^2)$

$$a(x) = \arg \max_{y \in Y} \Gamma_y(x) = \text{sign} \left(\underbrace{\Gamma_{+1}(x) - \Gamma_{-1}(x)} \right)$$

ширина окна: $h = 0.2$

чем меньше ширина окна h ,
тем сложнее форма границы,
возможно переобучение

чем больше ширина окна h ,
тем проще форма границы,
возможно недообучение



Влияние ширины окна h на вид разделяющей поверхности


Пример: $x_i \in \mathbb{R}^2$, $y_i \in \{-1, +1\}$, гауссовское $K(z) = \exp(-2z^2)$

$$a(x) = \arg \max_{y \in Y} \Gamma_y(x) = \text{sign} \left(\underbrace{\Gamma_{+1}(x) - \Gamma_{-1}(x)} \right)$$

ширина окна: $h = 0.3$

чем меньше ширина окна h ,
тем сложнее форма границы,
возможно переобучение

чем больше ширина окна h ,
тем проще форма границы,
возможно недообучение



Влияние ширины окна h на вид разделяющей поверхности


Пример: $x_i \in \mathbb{R}^2$, $y_i \in \{-1, +1\}$, гауссовское $K(z) = \exp(-2z^2)$

$$a(x) = \arg \max_{y \in Y} \Gamma_y(x) = \text{sign} \left(\underbrace{\Gamma_{+1}(x) - \Gamma_{-1}(x)} \right)$$

ширина окна: $h = 0.5$

чем меньше ширина окна h ,
тем сложнее форма границы,
возможно переобучение

чем больше ширина окна h ,
тем проще форма границы,
возможно недообучение



Влияние ширины окна h на вид разделяющей поверхности


Пример: $x_i \in \mathbb{R}^2$, $y_i \in \{-1, +1\}$, гауссовское $K(z) = \exp(-2z^2)$

$$a(x) = \arg \max_{y \in Y} \Gamma_y(x) = \text{sign} \left(\underbrace{\Gamma_{+1}(x) - \Gamma_{-1}(x)} \right)$$

ширина окна: $h = 1.0$

чем меньше ширина окна h ,
тем сложнее форма границы,
возможно переобучение

чем больше ширина окна h ,
тем проще форма границы,
возможно недообучение



Влияние ширины окна h на вид разделяющей поверхности


Пример: $x_i \in \mathbb{R}^2$, $y_i \in \{-1, +1\}$, гауссовское $K(z) = \exp(-2z^2)$

$$a(x) = \arg \max_{y \in Y} \Gamma_y(x) = \text{sign} \left(\underbrace{\Gamma_{+1}(x) - \Gamma_{-1}(x)} \right)$$

ширина окна: $h = 5.0$

чем меньше ширина окна h ,
тем сложнее форма границы,
возможно переобучение

чем больше ширина окна h ,
тем проще форма границы,
возможно недообучение




Влияние ширины окна h на качество классификации

Пример.

Задача UCI: Iris.

$$\text{LOO}(h) = \sum_{i=1}^{\ell} [a_h(x_i; X^{\ell} \setminus \{x_i\}) \neq y_i] \rightarrow \min_h$$

частота ошибок



- смещённое число ошибок, когда объект учитывается как сосед самого себя
- несмещённое число ошибок LOO — позволяет оптимизировать ширину окна

Выбор ядра K и ширины окна h

- Ядро $K(z)$
 - влияет на гладкость разделяющей поверхности
 - почти не влияет на качество классификации
 - финитные ядра ускоряют поиск ближайших соседей
- Ширина окна h
 - существенно влияет на качество классификации
- Переменная ширина окна по k ближайшим соседям:

$$S(x, x_i) = K\left(\frac{\rho(x, x_i)}{h(x)}\right), \quad h(x) = \rho(x, x^{(k+1)})$$

где $x^{(k)}$ — k -й сосед объекта x из обучающей выборки X^ℓ

- Оптимизация ширины окна (h или k) по leave-one-out:

$$\text{LOO}(h, X^\ell) = \sum_{i=1}^{\ell} [a_h(x_i; X^\ell \setminus \{x_i\}) \neq y_i] \rightarrow \min_h$$

Оценка обобщающей способности (generalization performance)

Полный скользящий контроль (complete cross-validation, CCV):

$$\text{CCV}(X^L) = \frac{1}{C_L^\ell} \sum_{X^\ell \sqcup X^k} \frac{1}{k} \sum_{x_i \in X^k} [a(x_i; X^\ell) \neq y_i],$$

— частота ошибок алгоритма на контрольной выборке X^k , усреднённая по всем C_L^ℓ разбиениям выборки $X^L = X^\ell \sqcup X^k$ на обучающую подвыборку X^ℓ и контрольную X^k .

Замечание. При $k = 1$ имеем: $\text{CCV}(X^L) = \text{LOO}(X^L)$.

Задача.

От чего зависит обобщающая способность CCV метода 1NN?

Возможно ли улучшить алгоритм 1NN, минимизируя CCV?

Понятие профиля компактности

Профиль компактности выборки X^L — это функция доли объектов x_i , у которых m -й сосед $x_i^{(m)}$ лежит в другом классе:

$$\Pi(m) = \frac{1}{L} \sum_{i=1}^L [y_i \neq y_i^{(m)}]; \quad m = 1, \dots, L-1,$$

$x_i^{(m)}$ — m -й сосед объекта x_i среди X^L ;

$y_i^{(m)}$ — ответ на m -м соседе объекта x_i .


Теорема (точное выражение CCV для метода 1NN)

$$\text{CCV}(X^L) = \sum_{m=1}^k \Pi(m) \frac{C_{L-1-m}^{\ell-1}}{C_{L-1}^{\ell}}.$$

Mullin M., Sukthankar R. Complete cross-validation for nearest neighbor classifiers. 2000

Воронцов К.В. Комбинаторный подход к оценке качества обучаемых алгоритмов. 2004

Пример. Профили компактности для серии модельных задач



средний ряд — профиль компактности $P(m)$

нижний ряд — зависимость $CCV(k)$ от длины контроля k

Доказательство (точное выражение CCV для метода 1NN)

Основная идея — просуммировать по разбиениям аналитически:

$$\begin{aligned}
 \text{CCV} &= \frac{1}{C_L^\ell} \sum_{X^\ell \sqcup X^k} \frac{1}{k} \sum_{i=1}^L [x_i \in X^k] [a(x_i; X^\ell) \neq y_i] = \\
 &= \sum_{X^\ell \sqcup X^k} \sum_{i=1}^L \sum_{m=1}^k \frac{[y_i^{(m)} \neq y_i]}{k C_L^\ell} [x_i^{(m)} \in X^\ell] [x_i, x_i^{(1)}, \dots, x_i^{(m-1)} \in X^k] = \\
 &= \sum_{m=1}^k \sum_{i=1}^L \frac{[y_i^{(m)} \neq y_i]}{k C_L^\ell} \sum_{X^\ell \sqcup X^k} [x_i^{(m)} \in X^\ell] [x_i, x_i^{(1)}, \dots, x_i^{(m-1)} \in X^k] = \\
 &= \sum_{m=1}^k \sum_{i=1}^L \frac{[y_i^{(m)} \neq y_i]}{k C_L^\ell} C_{L-1-m}^{\ell-1} = \sum_{m=1}^k \underbrace{\frac{1}{L} \sum_{i=1}^L [y_i^{(m)} \neq y_i]}_{\Pi(m)} \frac{C_{L-1-m}^{\ell-1}}{C_{L-1}^\ell}.
 \end{aligned}$$

Некоторые свойства профиля компактности и оценки CCV

- $R(m) = \frac{C_{L-1-m}^{\ell-1}}{C_{L-1}^{\ell}} \rightarrow 0$ быстрее геометрической прогрессии:

$$\frac{R(m+1)}{R(m)} = 1 - \frac{\ell-1}{L-1-m} < \frac{k}{L-1}.$$

- **Формализация гипотезы компактности:**

$CCV = \sum_{m=1}^k \Pi(m)R(m)$ тем меньше,
чем чаще близкие объекты лежат в одном классе.

- При малых k

$$k = 1: \quad CCV = \Pi(1) = LOO;$$

$$k = 2: \quad CCV = \Pi(1)\frac{\ell}{\ell+1} + \Pi(2)\frac{1}{\ell+1};$$

$$k = 3: \quad CCV = \Pi(1)\frac{\ell}{\ell+2} + \Pi(2)\frac{2\ell}{(\ell+1)(\ell+2)} + \Pi(3)\frac{2}{(\ell+1)(\ell+2)}.$$

- CCV слабо зависит от длины контроля k

Задача отбора эталонов $\Omega \subseteq X^L$ (prototype learning)

$a(x; X^L \cap \Omega)$ — классификатор 1NN, использующий только объекты из Ω в качестве ближайших соседей.

Требуется найти оптимальное подмножество эталонов Ω .

Определение (профиль компактности относительно Ω)

$$P(m, \Omega) = \frac{1}{L} \sum_{i=1}^L [y_i^{(m|\Omega)} \neq y_i]; \quad m = 1, \dots, |\Omega|,$$

где $x_i^{(m|\Omega)}$ — m -й сосед объекта x_i из множества Ω

Теорема

$$CCV(\Omega) = \frac{1}{L} \sum_{i=1}^L \underbrace{\sum_{m=1}^k [y_i^{(m|\Omega)} \neq y_i] \frac{C_{L-1-m}^{\ell-1}}{C_{L-1}^{\ell}}}_{T(x_i, \Omega) \text{ — вклад объекта } x_i \text{ в } CCV}$$

Жадный отбор эталонов Ω по критерию $CCV(\Omega) \rightarrow \min$

Жадная стратегия удаления не-эталонов:

$\Omega := X^L$;

повторять

 найти $x \in \Omega$: $CCV(\Omega \setminus \{x\}) \rightarrow \min$;

$\Omega := \Omega \setminus \{x\}$; обновить $T(x_i, \Omega)$ для всех x_i : $x \in kNN(x_i)$;

пока CCV уменьшается или почти не увеличивается;

Жадная стратегия добавления эталонов:

$\Omega := \{\text{по одному объекту от каждого класса}\}$;


повторять

 найти $x \in X^L \setminus \Omega$: $CCV(\Omega \cup \{x\}) \rightarrow \min$;

$\Omega := \Omega \cup \{x\}$; обновить $T(x_i, \Omega)$ для всех x_i : $x \in kNN(x_i)$;

пока CCV уменьшается;


Пример. Эксперимент на синтетических данных




Синтетическая задача классификации:

2 класса по 500 объектов, добавлено 30 шумовых объектов

Последовательное жадное удаление не-эталонных объектов




Последовательное жадное добавление эталонных объектов



Последовательное жадное удаление не-эталонных объектов

Зависимость CСV от числа удаленных неэталонных объектов.



При отборе эталонов по критерию CСV переобучения нет.

Воронцов К.В., Иванов М.Н. Отбор эталонов, основанный на минимизации функционала полного скользящего контроля. 2009

Задачи регрессии и метод наименьших квадратов

Дано: $X^\ell = (x_i, y_i)_{i=1}^\ell$ — обучающая выборка, $y_i \in \mathbb{R}$

Найти регрессионную модель для аппроксимации $y(x)$:

$$a(x) = f(x, \theta)$$

где θ — вектор параметров, f — фиксированная функция

Критерий — метод наименьших квадратов:

$$Q(\theta, X^\ell) = \sum_{i=1}^{\ell} w_i (f(x_i, \theta) - y_i)^2 \rightarrow \min_{\theta},$$

где w_i — весовой коэффициент, степень важности объекта x_i

Мотивация перехода к непараметрическим моделям:
когда нет теории, дающей «физичную» модель $f(x, \theta)$

Непараметрическая регрессия, формула Надарая–Ватсона

Приближение константой $f(x, \theta) = \theta$ в окрестности точки x :

$$Q(\theta; X^\ell) = \sum_{i=1}^{\ell} w_i(x) (\theta - y_i)^2 \rightarrow \min_{\theta \in \mathbb{R}};$$

где $w_i(x) = K\left(\frac{1}{h}\rho(x, x_i)\right)$ — веса объектов x_i в окрестности x ;
 $K(z)$ — ядро (kernel), невозрастающее, ограниченное, гладкое;
 h — ширина окна сглаживания (bandwidth).

Формула ядерного сглаживания Надарая–Ватсона:

$$a_h(x; X^\ell) = \frac{\sum_{i=1}^{\ell} y_i w_i(x)}{\sum_{i=1}^{\ell} w_i(x)} = \frac{\sum_{i=1}^{\ell} y_i K\left(\frac{\rho(x, x_i)}{h}\right)}{\sum_{i=1}^{\ell} K\left(\frac{\rho(x, x_i)}{h}\right)}$$

Обоснование формулы Надарая–Ватсона (одномерный случай)

Теорема

Пусть выполнены следующие условия:

- 1) выборка $X^\ell = (x_i, y_i)_{i=1}^\ell$ простая, из распределения $p(x, y)$;
- 2) ядро $K(z)$ ограничено: $\int_0^\infty K(z) dz < \infty$, $\lim_{z \rightarrow \infty} zK(z) = 0$;
- 3) зависимость $E(y|x)$ не имеет вертикальных асимптот:
 $E(y^2|x) = \int_Y y^2 p(y|x) dy < \infty$ при любом $x \in X$;
- 4) последовательность h_ℓ убывает, но не слишком быстро:
 $\lim_{\ell \rightarrow \infty} h_\ell = 0$, $\lim_{\ell \rightarrow \infty} \ell h_\ell = \infty$.


Тогда имеет место сходимость по вероятности:

$$a_{h_\ell}(x; X^\ell) \xrightarrow{P} E(y|x) \text{ в любой точке } x \in X,$$

в которой $E(y|x)$, $p(x)$ и $D(y|x)$ непрерывны и $p(x) > 0$.

Влияние ядра K и ширины окна h на вид аппроксимации

$h \in \{0.1, 1.0, 3.0\}$, гауссовское ядро $K(z) = \exp(-2z^2)$




Гауссовское ядро $\Rightarrow$ гладкая аппроксимация

Ширина окна существенно влияет на точность аппроксимации

Влияние ядра K и ширины окна h на вид аппроксимации

$h \in \{0.1, 1.0, 3.0\}$, треугольное ядро $K(z) = (1 - |z|) [|z| \leq 1]$




Треугольное ядро $\Rightarrow$ кусочно-линейная аппроксимация

Аппроксимация не определена, если в окне нет точек выборки

Влияние ядра K и ширины окна h на вид аппроксимации

$h \in \{0.1, 1.0, 3.0\}$, прямоугольное ядро $K(z) = [|z| \leq 1]$



Прямоугольное ядро $\Rightarrow$ кусочно-постоянная аппроксимация
Выбор ядра слабо влияет на точность аппроксимации

Выбор ядра K и ширины окна h

- Ядро $K(z)$
 - влияет на гладкость аппроксимирующей функции $a_h(x)$
 - почти не влияет на качество аппроксимации
- Ширина окна h
 - существенно влияет на качество аппроксимации
- Переменная ширина окна по k ближайшим соседям:

$$w_i(x) = K\left(\frac{\rho(x, x_i)}{h(x)}\right), \quad h(x) = \rho(x, x^{(k+1)})$$

где $x^{(k)}$ — k -й сосед объекта x

- Оптимизация ширины окна (h или k) по leave-one-out:

$$\text{LOO}(h, X^\ell) = \sum_{i=1}^{\ell} \left(a_h(x_i; X^\ell \setminus \{x_i\}) - y_i \right)^2 \rightarrow \min_h$$

- Метрические методы — простейшие в машинном обучении, обучение сводится к запоминанию выборки (lazy learning)
- Усложняя метрические методы, можно обучать:
 - число ближайших соседей k или ширину окна h
 - веса (значимости, информативности) объектов
 - множество эталонов (prototype learning)
 - метрику (distance learning, similarity learning),
в частности, веса признаков в метрике Минковского
- Метод потенциальных функций = линейный классификатор
расстояние до опорного объекта = новый признак
- Качество обучения зависит от метрики и ширины окна, слабо зависит от вида ядра сглаживания
- Непараметрические методы обходятся без модели?
Нет, моделируется функция сходства между объектами

Важные в ML принципы, на примере метрических методов

- *Эвристики* — изобретательные приёмы или рецепты, упрощающие построение модели и решение задачи, но не гарантирующие качество решения
- *Математические теории* в машинном обучении служат для
 - обоснования эвристических методов,
 - в том числе, выявление условий их применимости,
 - лучшего понимания моделей и методов,
 - на его основе, изобретения более совершенных эвристик
- Увы, легко доказываемые обоснования, свойства, оценки, как правило, не слишком полезны на практике
- Увы, наиболее практически полезные эвристики, как правило, не удаётся обосновать десятилетиями