Методы машинного обучения. Предобработка данных и оценивание моделей

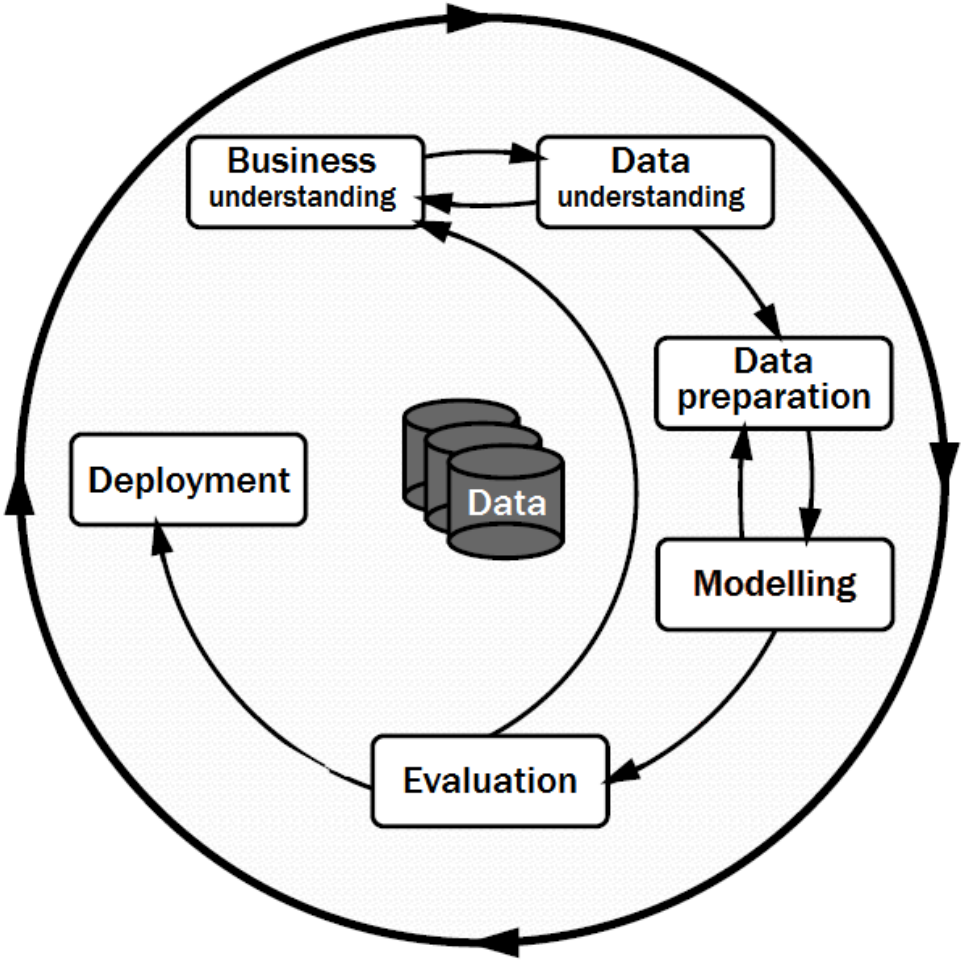
Воронцов Константин Вячеславович
www.MachineLearning.ru/wiki?title=User:Vokov
вопросы к лектору: vorontsovkv@my.msu.ru

материалы курса:
github.com/MSU-ML-COURSE/ML-COURSE-26-27
орг.вопросы по курсу: ml.cmc@mail.ru

ВМК МГУ • 6 октября 2026

Межотраслевой стандарт интеллектуального анализа данных

CRISP-DM: CRoss Industry Standard Process for Data Mining (1999)



Компании-инициаторы:

- SPSS
- Teradata
- Daimler AG
- NCR Corp.
- OHRA

Шаги процесса:

- понимание бизнеса
- понимание данных
- предобработка данных и инженерия признаков
- **разработка моделей и настройка параметров**
- оценивание качества
- внедрение

Содержание

1. **Предварительная обработка данных**
   - Преобразование признаков
   - Обработка пропущенных значений
   - Генерация признаков
2. **Оценки качества классификации**
   - Чувствительность, специфичность, ROC, AUC
   - Правдоподобие вероятностной модели классификации
   - Точность, полнота, AUC-PR
3. **Анализ ошибок и выбор моделей**
   - Обобщающая способность
   - Анализ ошибок
   - Выбор моделей

Шкалы измерения

Измерительная шкала — множество D допустимых значений, получаемых в результате измерения признака $f(x)$, $f: X \to D$

Тип шкалы определяется множествами

- допустимых биективных преобразований $\psi: D \to D'$
- допустимых операций над значениями из шкалы D

Классификация типов измерительных шкал по Стивенсу:

шкала	D	$\psi(z)$	операции
логическая (boolean)	$0, 1$	биективные	$= \neq \vee \wedge \neg$
номинальная (nominal)	$< \infty$	биективные	$= \neq \in$
порядковая (ordinal)	$< \infty$	монотонные	$= \neq \in < >$
интервальная (interval)	$\mathbb{R}$	$az + b$	$\leqslant \geqslant + -$
отношений (ratio)	$\mathbb{R}$	az	$\leqslant \geqslant + - \times \div$
абсолютная (absolute)	$\mathbb{R}$	z	любые

S.S.Stevens. On the Theory of Scales of Measurement // Science, 1946.

Примеры величин, измеряемых в различных шкалах

- **Логическая** (можно переименовать, перенумеровать)
  наличие/отсутствие свойства, истина/ложь, да/нет
- **Номинальная** (можно переименовать, перенумеровать)
  идентификаторы классов, людей, регионов, фирм, товаров
- **Порядковая** (порядок частичный или линейный)
  уровень образования, тяжесть болезни, степень согласия
- **Ранговая** (частный случай порядковой: $1, 2, 3, \ldots, N$)
  оценка в баллах, шкалы Рихтера, Бофорта, Мооса, Бека
- **Интервальная** (можно менять масштаб и сдвигать 0)
  время, географическая широта, температура ($^\circ$C, $^\circ$F)
- **Отношений** (можно менять масштаб, сдвигать 0 нельзя)
  масса, скорость, объём, сила, давление, заряд, яркость, $^\circ$K
- **Абсолютная** (любые преобразования запрещены)
  число предметов, частота события, оценка вероятности

Ослабление шкалы

Номинальный $\to$ **много бинарных** (one-hot-encoding):

- $f_v(x) = \left[f(x) = v\right]$, для всех значений v признака
- $f_A(x) = \left[f(x) \in A\right]$, для некоторых подмножеств A

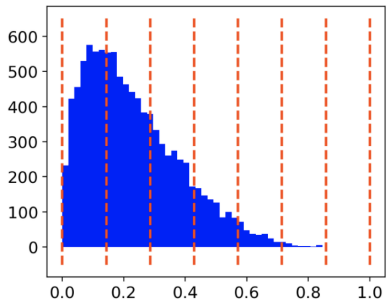
Числовой или порядковый $\to$ **бинарный:**

- $f_{a,b}(x) = \left[a \leqslant f(x) \leqslant b\right]$, для некоторого отрезка $[a, b]$

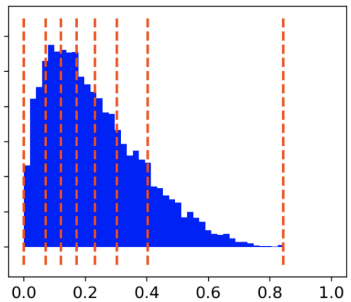
Числовой $\to$ **ранговый** (data binning, quantization):

- $f_a(x) = \sum_{k=1}^{K} \left[f(x) \geqslant a_k\right]$, номер интервала сетки $a_1, \ldots, a_K$

равномерная сетка



квантильная сетка



Ослабление шкалы всегда влечёт потерю информации

Усиление шкалы

Номинальный $\to$ числовой:

- категория заменяется её частотой в выборке:
$$f'(x) = \frac{1}{\ell}\sum_{i=1}^{\ell}\big[f(x_i) = f(x)\big]$$
- условное среднее числового признака $g(x)$:
$$f'(x) = \operatorname{mean}\big(g|f(x)\big) = \frac{\sum_{i=1}^{\ell} g(x_i)\big[f(x_i) = f(x)\big]}{\sum_{i=1}^{\ell}\big[f(x_i) = f(x)\big]},$$
- условное среднее целевой величины $y(x)$:
$f'(x) = \operatorname{mean}\big(y|f(x)\big)$, возможно переобучение!

Порядковый $\to$ числовой (монотонное преобразование)

- значение заменяется частотой меньших значений:
$$f'(x) = \frac{1}{\ell}\sum_{i=1}^{\ell}\big[f(x_i) \leqslant f(x)\big]$$

Нормализация и стандартизация числовых шкал

Многие методы накапливают меньше вычислительных погрешностей, если признаки приведены к одному масштабу

- $f'_j(x) = \dfrac{f_j(x) - f_j^{\min}}{f_j^{\max} - f_j^{\min}}$ — нормализация, приведение к $[0, 1]$
- $f'_j(x) = \dfrac{f_j(x)}{|f_j|^{\max}}$ — масштабирование с сохранением нуля
- $f'_j(x) = \dfrac{f_j(x) - \mu_j}{\sigma_j}$ — стандартизация

$f_j^{\max}$, $|f_j|^{\max}$, $f_j^{\min}$, μ_j, σ_j определяются по обучающей выборке

Для повышения устойчивости к выбросам можно отбрасывать 5% наименьших и наибольших значений признака

Трансформация вида распределения

F_j — функция распределения (c.d.f.) признака f_j
Эмпирическая функция распределения (кусочно-постоянная):

$$\hat{F}_j(z) = \frac{1}{\ell} \sum_{i=1}^{\ell} \left[f_j(x_i) \leqslant z \right]$$

- $f'_j(x) = F_j(f_j(x))$ — преобразование $f_j(x)$ в равномерную на отрезке $[0, 1]$ случайную величину
- $f'_j(x) = \Phi^{-1}\big(F_j(f_j(x))\big)$ — преобразование $f_j(x)$ в случайную величину с заданной функцией распределения Φ (например, в нормальную)
- $f'_j(x) = \ln\big(1 + f_j(x)\big)$ — преобразование неотрицательной случайной величины «с тяжёлым правым хвостом» (объёмы производства, перевозок, продаж)

Подходы к обработке пропущенных значений

- Игнорировать объекты или признаки с пропусками
  — ведёт к потере информации :(
- Заполнить пропущенные значения признака f:
  — средним или медианным значением $\bar{f}$
- Прогнозировать значения признака f по остальным:
  — регрессия для вещественного признака f
  — классификация для дискретного признака f
  — матричные разложения, например, разреженный SVD
- Использовать модели, способные обрабатывать пропуски:
  — решающие деревья
  — голосование низкоразмерных базовых предикторов
- Ввести бинарный признак $\tilde{f}(x) = [f(x) \text{ не известно}]$

Непараметрическая регрессия для заполнения пропусков

Формула Надарая–Ватсона, ядерное сглаживание:

$$\hat{f}_j(x_i) = \frac{\sum_u f_j(u) S(u, x_i)}{\sum_u S(u, x_i)}$$

где $\sum_u$ — сумма по всем объектам $u \in X^\ell$ с известным $f_j(u)$

Варианты функций сходства (similarity) объектов $S(u, x)$:

- $S(u,x) = K\left(\frac{\rho(u,x)}{h}\right), \quad \rho^2(u,x) = \frac{1}{|J_{ux}|} \sum_{j \in J_{ux}} \big(f_j(u) - f_j(x)\big)^2$
- $S(u,x) = \frac{1}{|J_{ux}|} \sum_{j \in J_{ux}} f_j(u) f_j(x)$ — скалярное произведение
- $S(u,x) = \frac{\sum_{j \in J_{ux}} f_j(u) f_j(x)}{\sqrt{\sum_{j \in J_{ux}} f_j^2(u)} \sqrt{\sum_{j \in J_{ux}} f_j^2(x)}}$ — косинусная ф.сх.

где J_{ux} — множество признаков j с известными $f_j(x)$ и $f_j(u)$

Разреженное низкоранговое матричное разложение

Дано: матрица $F = \big(f_{ij} = f_j(x_i)\big)_{\ell \times n}$, $\Omega \subseteq \{1, \ldots, \ell\} \times \{1, \ldots, n\}$

Найти: матрицы $G = (g_{it})_{\ell \times k}$ и $U = (u_{jt})_{n \times k}$ такие, что

$$\big\|F - GU^{\mathsf{T}}\big\| = \sum_{(i,j)\in\Omega} \underbrace{\big(f_{ij} - \langle g_i, u_j\rangle\big)}_{\varepsilon_{ij}}^2 = \sum_{(i,j)\in\Omega} \Big(f_{ij} - \sum_{t=1}^{k} g_{it} u_{jt}\Big)^2 \to \min_{G,U}$$

Классический SVD неприменим для разреженной задачи.

Метод стохастического градиента: перебираем $(i,j) \in \Omega$ в случайном порядке, делаем градиентные шаги $(\varepsilon_{ij})^2 \to \min\limits_{g_i, u_j}$:

$$g_{it} := g_{it} + \eta \varepsilon_{ij} u_{jt}, \quad t = 1, \ldots, k$$
$$u_{jt} := u_{jt} + \eta \varepsilon_{ij} g_{it}, \quad t = 1, \ldots, k$$

$\hat{f}_j(x_i) = \langle g_i, u_j\rangle$ — восстановление пропущенных значений

g_{it} — новые признаки x_i в пространстве размерности k

Конструирование признаков по «сырым» данным (raw data)

Feature Engineering: признаки вычисляются по формулам, которые зависят от задачи, требуют изобретательности и знаний предметной области. Долго, дорого, неточно.

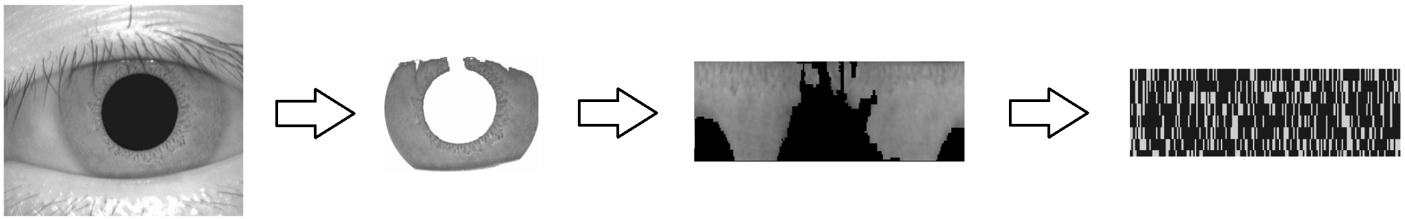
- **Прогнозирование временных рядов:**
  признаки агрегируются по предыстории различной глубины
- **Предсказание оттока клиентов:**
  признаки структуры и объёма услуг, оплаты, тарифов
- **Распознавание лиц:**
  признаки размера и формы черт лица
- **Классификация и поиск текстов:**
  признаки частоты слов, терминов, названий, синонимов
- **Распознавание речи:**
  признаки спектральные, фонетические, лингвистические

Пример (напоминание). Биометрическая идентификация

Идентификация личности по отпечаткам пальцев



Идентификация личности по радужной оболочке глаза



Особенности задач:

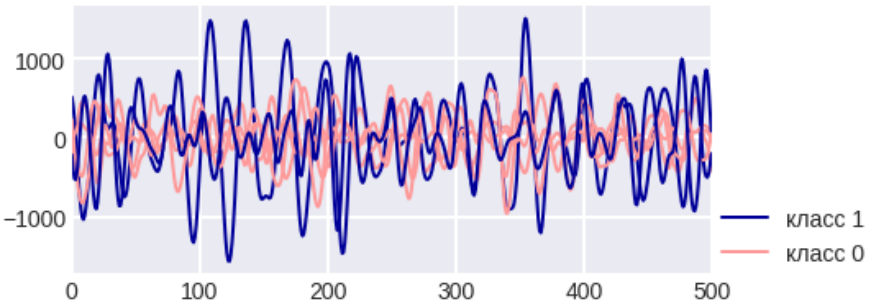
- нетривиальная предобработка для извлечения признаков
- высочайшие требования к точности

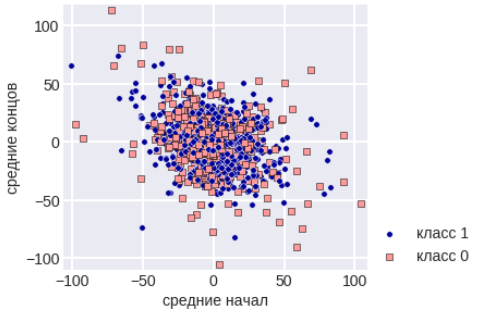
J. Daugman. High confidence visual recognition of persons by a test of statistical independence. 1993

Пример. Задача детектирования поломок по сигналу датчика

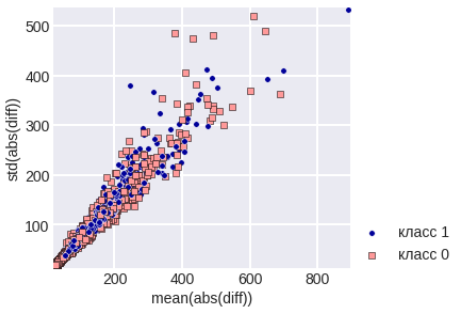
Соревнование «Ford Classification Challenge», 2008
Иногда при удачном выборе признаков задача решается без ML

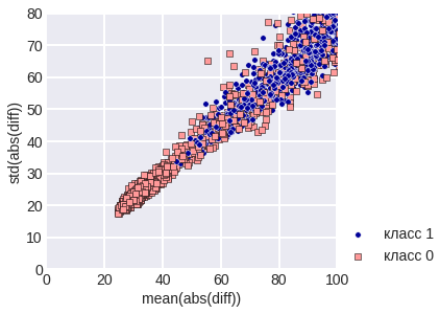
Признаки, генерируемые по исходным временным рядам, слабы:

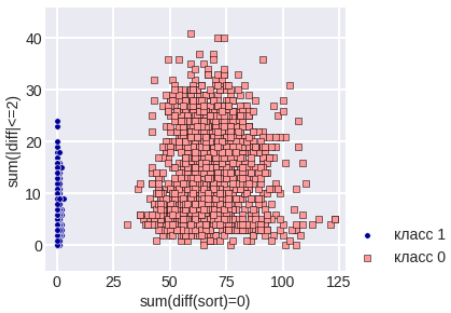




Среди признаков рядов их производных оказывается идеальный:



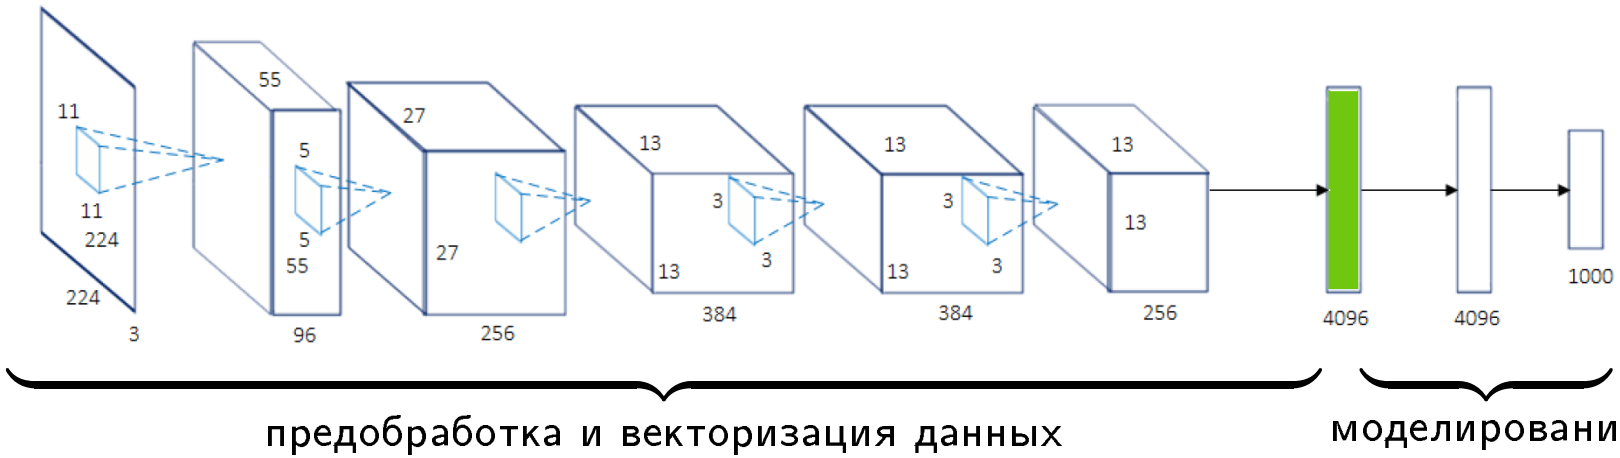




https://dyakonov.org/2018/06/28/простые-методы-анализа-данных

Обучаемая векторизация данных

Глубокие нейронные сети объединяют два этапа обработки данных: векторизацию и предсказательное моделирование



- компьютерное зрение
- обработка текстов естественного языка
- анализ сигналов, распознавание и синтез речи
- анализ графов и транзакционных данных

— немного в следующем семестре, много в курсе DL

Krizhevsky A., Sutskever I., Hinton G. ImageNet classification with deep convolutional neural networks. 2012.

Резюме. Предварительная обработка данных

Данные могут быть

- разнородные (признаки измерены в разных шкалах)
- неполные (измерены не все, имеются пропуски)
- неточные (измерены с погрешностями)
- противоречивые (объекты одинаковые, ответы разные)
- избыточные (сверхбольшие, не помещаются в память)
- недостаточные (объектов меньше, чем признаков)
- сложно структурированные (нет признаковых описаний)

— и для всех этих проблем в ML известны решения!

«Грязные» данные — единственная проблема, для которой нет решения кроме «снова улучшать процессы сбора данных»

Ошибки первого и второго рода

Задача классификации на два класса: $y_i,\ a(x_i, w) \in \{-1, +1\}$

	модель классификации	учитель
TP, True Positive	$a(x_i) = +1$	$y_i = +1$
TN, True Negative	$a(x_i) = -1$	$y_i = -1$
FP, False Positive	$a(x_i) = +1$	$y_i = -1$
FN, False Negative	$a(x_i) = -1$	$y_i = +1$

FP: ложноположительно, ошибка I рода, «ложная тревога»
FN: ложноотрицательно, ошибка II рода, «пропуск цели»

Правильность классификации (чем больше, тем лучше):

$$\text{Accuracy} = \frac{1}{\ell}\sum_{i=1}^{\ell}\big[a(x_i) = y_i\big] = \frac{\text{TP} + \text{TN}}{\text{FP} + \text{FN} + \text{TP} + \text{TN}}$$

Недостаток: не учитывается дисбаланс численности классов, а также различие цены ошибки I и II рода.

ROC-кривая (Receiver Operating Characteristic)

Бинарный классификатор: $a(x; w, w_0) = \text{sign}\big(b(x, w) - w_0\big)$
Кривая ROC: как меняется качество a при варьировании w_0
(чем больше w_0, тем больше x_i, на которых $a(x_i) = -1$)

- по оси X: доля *ошибочных положительных классификаций* (FPR — false positive rate):

$$\text{FPR}(a) = \frac{\text{FP}}{\text{FP} + \text{TN}} = \frac{\sum_{i=1}^{\ell}[y_i = -1][a(x_i; w, w_0) = +1]}{\sum_{i=1}^{\ell}[y_i = -1]}$$

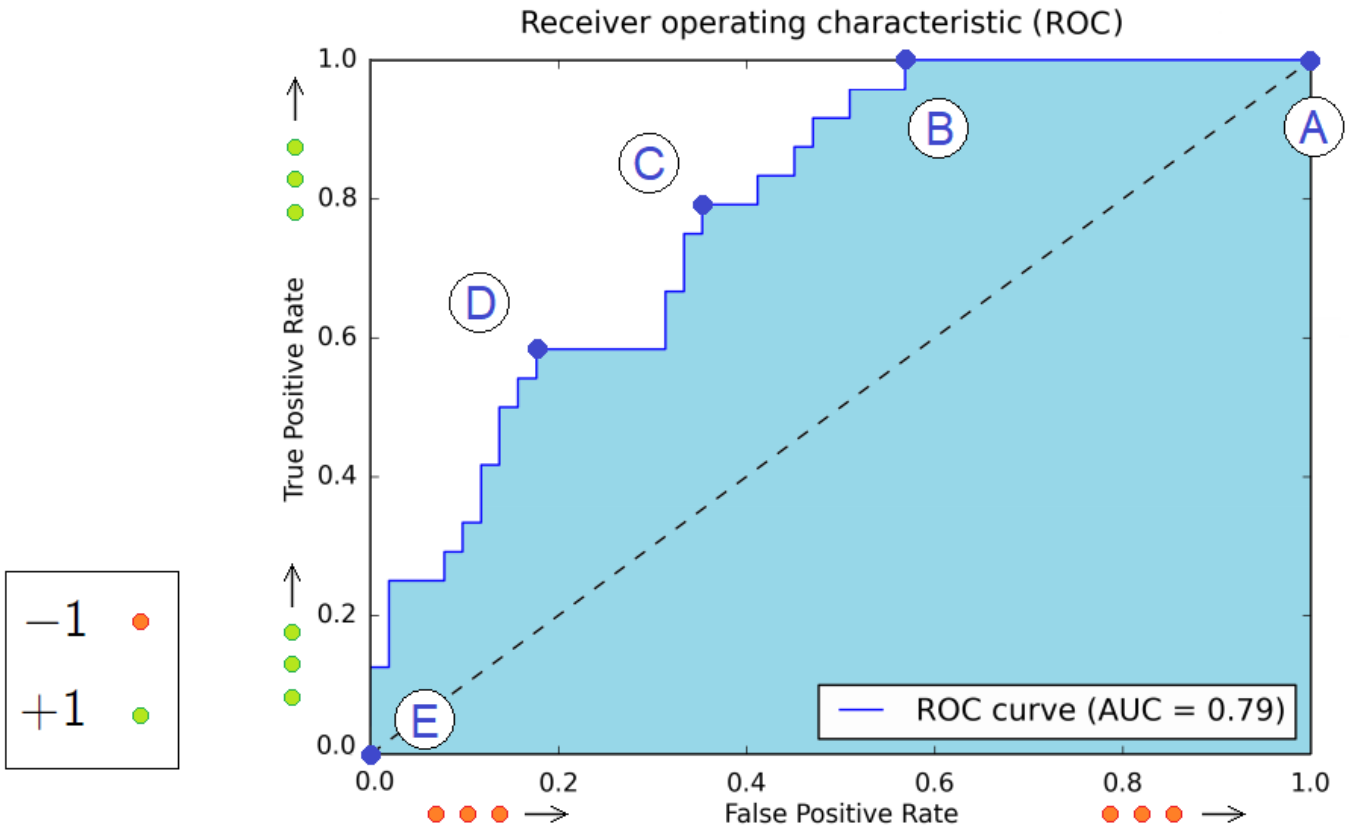
  $1 - \text{FPR}(a)$ называется *специфичностью* алгоритма a

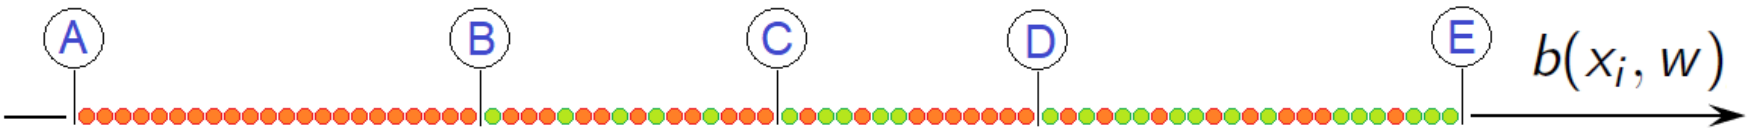
- по оси Y: доля *правильных положительных классификаций* (TPR — true positive rate):

$$\text{TPR}(a) = \frac{\text{TP}}{\text{TP} + \text{FN}} = \frac{\sum_{i=1}^{\ell}[y_i = +1][a(x_i; w, w_0) = +1]}{\sum_{i=1}^{\ell}[y_i = +1]}$$

  $\text{TPR}(a)$ называется также *чувствительностью* алгоритма a

Площадь под ROC-кривой AUC (Area Under Curve)





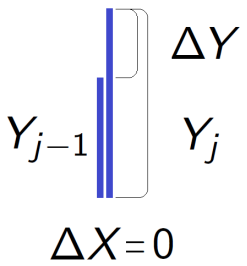
ABCDE — положения порога w_0 на оси значений функции b

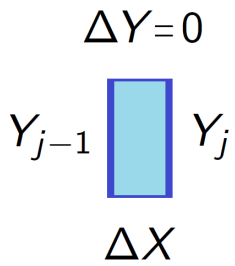
Алгоритм эффективного построения ROC-кривой

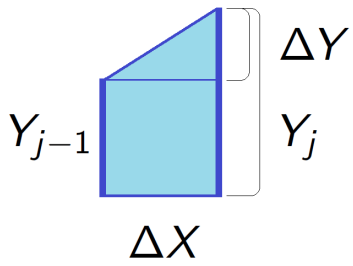
Вход: выборка $\{x_i\}_{i=1}^{\ell}$; дискриминантная функция $b(x, w)$;
Выход: ROC-кривая $(X_j, Y_j)_{j=0}^{k}$, $k \leqslant \ell$ и площадь AUC

$\ell_y := \sum_{i=1}^{\ell} [y_i = y]$, для всех $y \in Y$;
упорядочить $\{x_i\}$ по убыванию $b_i = b(x_i, w)$: $b_1 \geqslant \ldots \geqslant b_\ell$;
$(X_0, Y_0) := (0, 0)$; AUC $:= 0$; $\Delta X := 0$; $\Delta Y := 0$; $j := 1$;

для $i := 1, \ldots, \ell$
  $\Delta X := \Delta X + \frac{1}{\ell_-}[y_i = -1]$;
  $\Delta Y := \Delta Y + \frac{1}{\ell_+}[y_i = +1]$;
  если $(b_i \neq b_{i-1})$ **то**
    $X_j := X_{j-1} + \Delta X$;
    $Y_j := Y_{j-1} + \Delta Y$;
    AUC $:=$ AUC $+ \frac{1}{2}(Y_{j-1} + Y_j)\Delta X$;
    $j := j + 1$; $\Delta X := 0$; $\Delta Y := 0$;







Задача максимизации площади под кривой ROC-AUC

Бинарный классификатор: $a(x; w, w_0) = \text{sign}\big(b(x, w) - w_0\big)$

AUC — это доля правильно упорядоченных пар (x_i, x_j):

$$\text{AUC}(w) = \frac{1}{\ell_-} \sum_{i=1}^{\ell} \big[y_i = -1\big] \text{TPR}_i =$$

$$= \frac{1}{\ell_- \ell_+} \sum_{i=1}^{\ell} \sum_{j=1}^{\ell} \big[y_i < y_j\big] \big[b(x_i, w) < b(x_j, w)\big] \to \max_w$$

Критерий: максимум аппроксимированного AUC:

$$1 - \text{AUC}(w) \leqslant Q(w) = \sum_{i,j:\, y_i < y_j} L\Big(\underbrace{b(x_j, w) - b(x_i, w)}_{M_{ij}(w)}\Big) \to \min_w$$

где $L(M)$ — убывающая функция попарного отступа $M_{ij}(w)$

Метод SG: шаг по случайным парам объектов (x_i, x_j): $y_i < y_j$

$$w := w - h\, L'(M_{ij}(w)) \cdot \nabla_w \big(b(x_j, w) - b(x_i, w)\big)$$

Логарифм правдоподобия, log-loss

Вероятностная модель бинарной классификации, $y_i \in \{-1, +1\}$:

$$a(x, w) = \text{sign}\big(b(x, w) - w_0\big), \qquad b(x, w) = \text{P}(y = +1|x, w)$$

Проблема: ROC и AUC инвариантны относительно монотонных преобразований дискриминантной функции $b(x, w)$

Критерий логарифма правдоподобия (log-loss):

$$Q(w) = \sum_{i=1}^{\ell} [y_i = +1] \ln b(x, w) + [y_i = -1] \ln\big(1 - b(x, w)\big) \to \max_w$$

Вероятностная модель многоклассовой классификации:

$$a(x) = \arg\max_{y \in Y} \text{P}(y|x, w)$$

$$Q(w) = \sum_{i=1}^{\ell} \ln \text{P}(y_i|x_i, w) \to \max_w$$

Точность и полнота бинарной классификации

В информационном поиске не важен TN:

$$\text{Точность, Precision} = \frac{TP}{TP+FP}$$

$$\text{Полнота, Recall} = \frac{TP}{TP+FN}$$

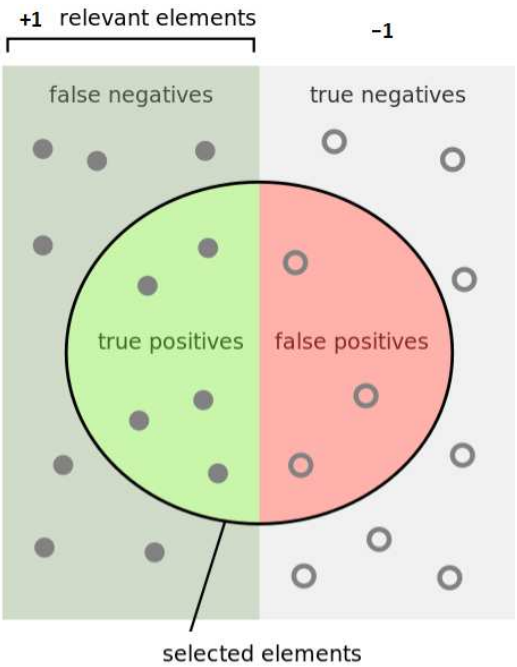
Precision — доля релевантных среди найденных
Recall — доля найденных среди релевантных

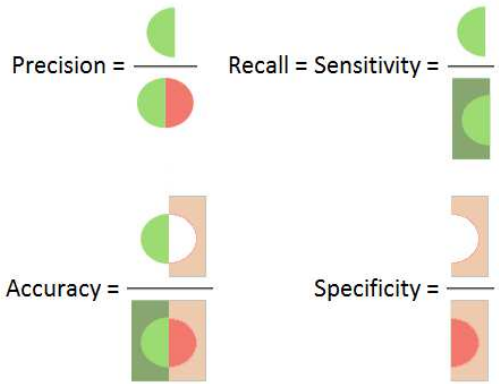
В медицинской диагностике важно всё:

$$\text{Чувствительность, Sensitivity} = \frac{TP}{TP+FN}$$

$$\text{Специфичность, Specificity} = \frac{TN}{TN+FP}$$

Sensitivity — доля верных положительных диагнозов
Specificity — доля верных отрицательных диагнозов





Точность и полнота многоклассовой классификации

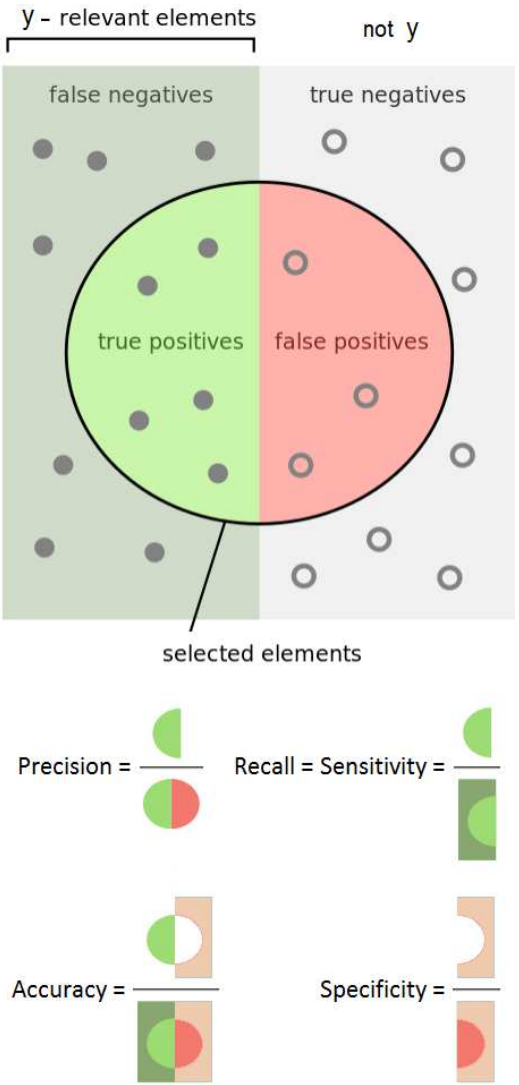
Для каждого класса $y \in Y$:
TP_y — верные положительные
FP_y — ложные положительные
FN_y — ложные отрицательные

Точность и полнота с микроусреднением:

$$\text{Precision: } P = \frac{\sum_y \mathrm{TP}_y}{\sum_y (\mathrm{TP}_y + \mathrm{FP}_y)};$$

$$\text{Recall: } R = \frac{\sum_y \mathrm{TP}_y}{\sum_y (\mathrm{TP}_y + \mathrm{FN}_y)};$$

Микроусреднение не чувствительно
к ошибкам на малочисленных классах



Точность и полнота многоклассовой классификации

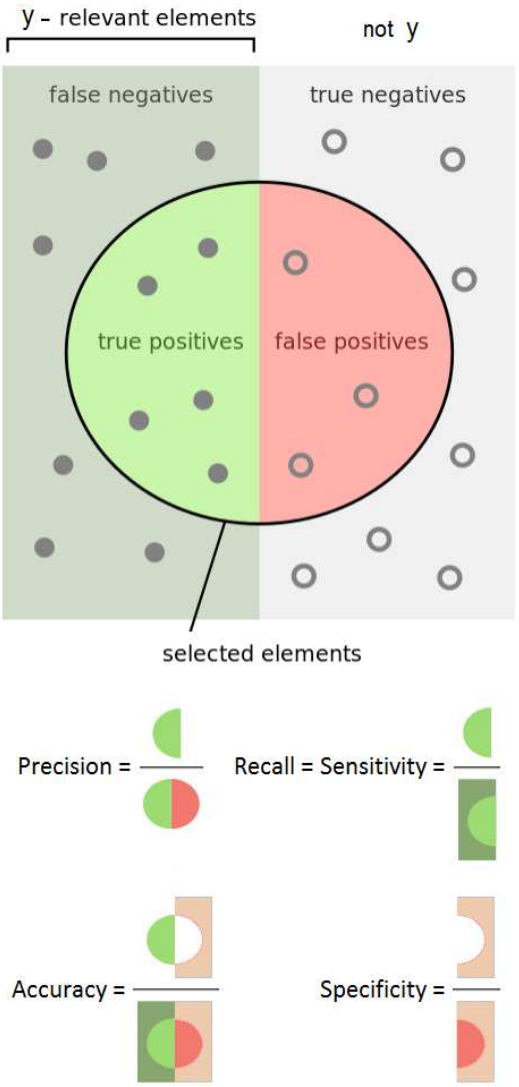
Для каждого класса $y \in Y$:
TP_y — верные положительные
FP_y — ложные положительные
FN_y — ложные отрицательные

Точность и полнота с макроусреднением:

$$\text{Precision: } P = \frac{1}{|Y|} \sum_y \frac{\mathrm{TP}_y}{\mathrm{TP}_y + \mathrm{FP}_y};$$

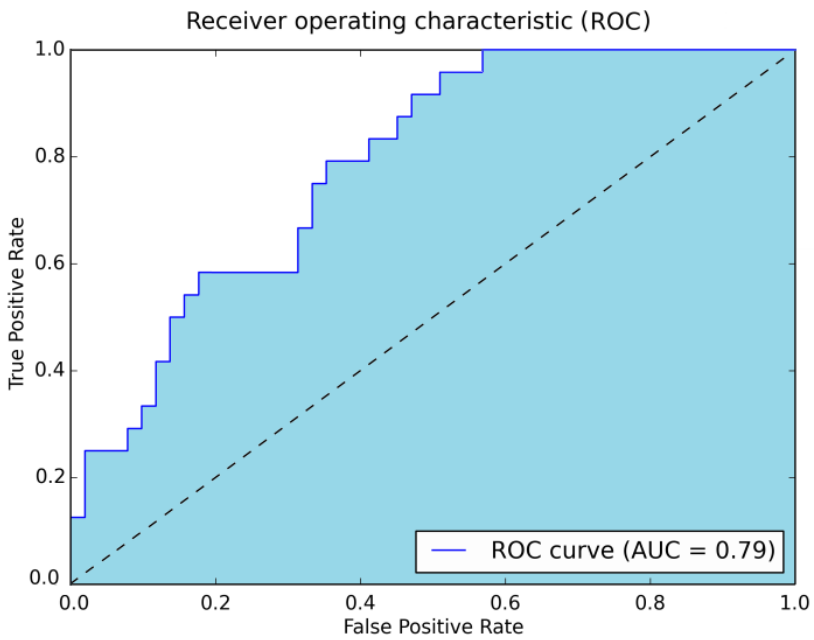
$$\text{Recall: } R = \frac{1}{|Y|} \sum_y \frac{\mathrm{TP}_y}{\mathrm{TP}_y + \mathrm{FN}_y};$$

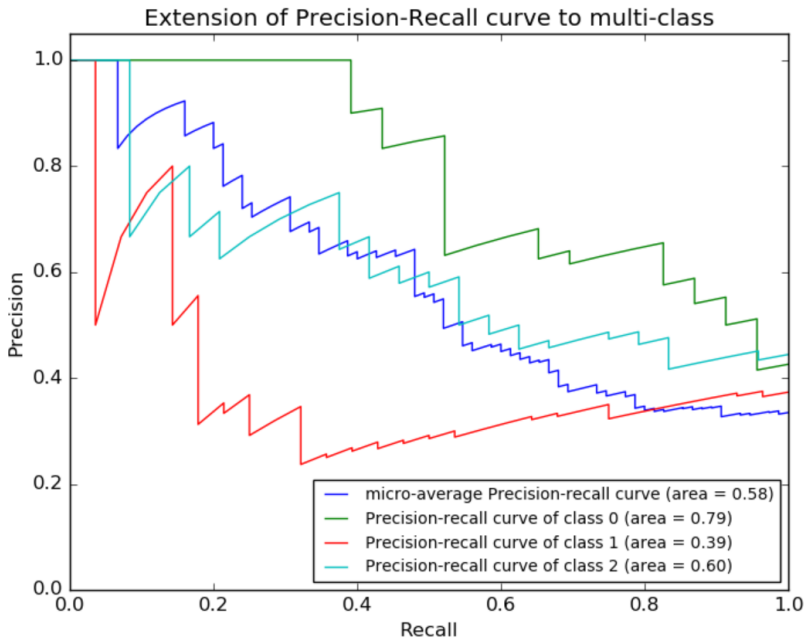
Макроусреднение чувствительно
к ошибкам на малочисленных классах



Кривые ROC и Precision-Recall

Бинарный классификатор: $a(x; w, w_0) = \text{sign}\big(b(x, w) - w_0\big)$
Каждая точка кривой соответствует значению порога w_0





AUROC — площадь под ROC-кривой
AUPRC — площадь под кривой Precision-Recall

Примеры из Python scikit learn: `http://scikit-learn.org/dev`

Резюме. Оценки качества классификации

- Чувствительность и специфичность лучше подходят для задач с несбалансированными классами
- Логарифм правдоподобия (log-loss) лучше подходит для оценки качества вероятностной модели классификации.
- Точность и полнота лучше подходят для задач поиска, когда доля объектов релевантного класса очень мала.

Агрегированные оценки:

- AUC лучше подходит для оценивания качества, когда соотношение цены ошибок не фиксировано.
- AUPRC — площадь под кривой точность–полнота.
- $F_1 = \frac{2PR}{P+R}$ — F-мера, другой способ агрегирования P и R.
- $F_\beta = \frac{(1+\beta^2)PR}{\beta^2 P+R}$ — F_β-мера: чем больше β, тем важнее R.

Задачи оценивания и выбора моделей

Дано:

$X^\ell = (x_1, \ldots, x_\ell)$ — обучающая выборка

$A_t = \{a \colon X \times W_t \to Y\}$ — параметрические модели, $t \in T$

W_t — пространство параметров модели A_t

$\mu_t \colon (X \times Y)^\ell \to W_t$ — методы обучения, $t \in T$

Найти: метод μ_t с наилучшей *обобщающей способностью*.

Частные случаи:

- выбор лучшей модели A_t (model selection);
- выбор метода обучения μ_t для заданной модели A (в частности, оптимизация *гиперпараметров*);
- отбор признаков (feature selection):
  $F = \{f_j \colon X \to D_j \colon j = 1, \ldots, n\}$ — множество признаков;
  метод обучения μ_J использует только признаки $J \subseteq F$.

Внутренние и внешние критерии качества обучения

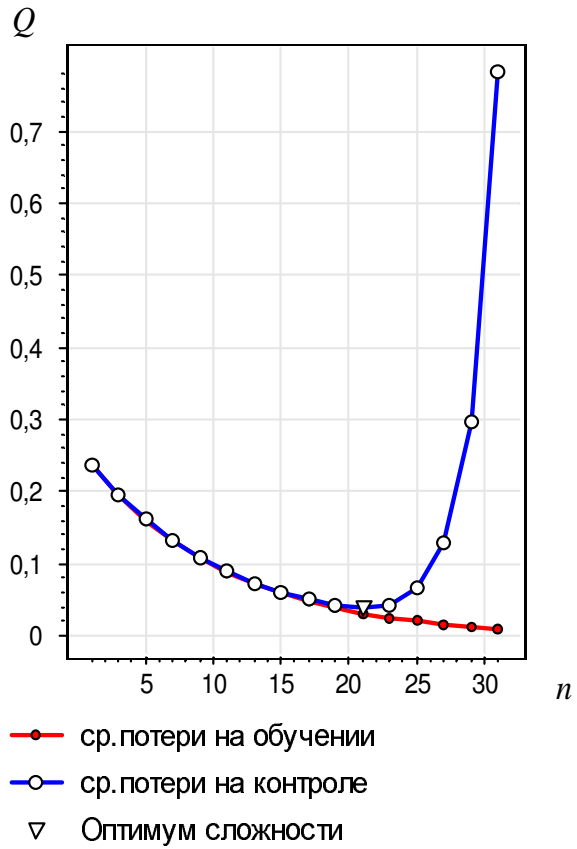
$\mathscr{L}(w, x)$ — функция потерь модели $a(w, x)$ на объекте x

$Q(w, X^\ell) = \frac{1}{\ell} \sum_{i=1}^{\ell} \mathscr{L}(w, x_i)$ — *функционал качества* $a(w, x)$ на X^ℓ

$Q\left(\mu(X^\ell), X^\ell\right)$ — *внутренний критерий*,
убывает с ростом сложности модели
(числа обучаемых параметров),
смещенная оценка $\mathsf{E}_{X^\ell, x} \mathscr{L}\left(\mu(X^\ell), x\right)$

$Q\left(\mu(X^\ell), X^k\right)$ — *внешний критерий*,
имеет минимум по сложности модели,
несмещённая оценка $\mathsf{E}_{X^\ell, x} \mathscr{L}\left(\mu(X^\ell), x\right)$

Недостаток оценки hold-out:
она зависит от разбиения $X^\ell \sqcup X^k$



Кросс-проверка (cross-validation, CV)

Усреднение по множеству разбиений $X^L = X^\ell_s \sqcup X^k_s$, $s \in S$:

$$\mathrm{CV}(\mu, X^L) = \frac{1}{|S|} \sum_{s \in S} Q\big(\mu(X^\ell_s), X^k_s\big)$$

- $|S| = 1$ — единственное (случайное) разбиение: *hold-out*
- S — множество случайных разбиений: *метод Монте-Карло*
- $S = \big\{(X^L \setminus \{x_i\}) \sqcup \{x_i\}\big\}_{i=1..L}$, каждый объект становится контролем один раз, *скользящий контроль* (*leave one out*)
- $S = \big\{(X^L \setminus B_s) \sqcup B_s\big\}_{s=1..q}$, где $B_1 \sqcup \cdots \sqcup B_q = X^L$ — разбиение *на q блоков* равной± 1 длины (q-fold CV), каждый объект участвует в контроле один раз
- $S = \big\{(X^L \setminus B^r_s) \sqcup B^r_s\big\}^{r=1..t}_{s=1..q}$, где $B^r_1 \sqcup \cdots \sqcup B^r_q = X^L$ — t разбиений *на q блоков* равной± 1 длины ($t \times q$-fold CV), каждый объект участвует в контроле ровно t раз
- S — все $C^k_{\ell+k}$ разбиений: *complete cross-validation*, CCV

Методология анализа ошибок (или потерь)

$\mathscr{L}(w, x_i)$ — функция потерь (чем меньше, тем лучше).
Среднее потерь на выборке U и эмпирическое распределение:

$$Q(w, U) = \frac{1}{|U|} \sum_{x_i \in U} \mathscr{L}(w, x_i)$$

$$F(\lambda; w, U) = \frac{1}{|U|} \sum_{x_i \in U} \left[\mathscr{L}(w, x_i) \leqslant \lambda\right]$$

Анализ потерь на обучающей выборке:

- Ранжировать объекты по убыванию потерь $\mathscr{L}_i = \mathscr{L}(w, x_i)$
- Объекты со сверхбольшими потерями — выбросы?
- Если нет, то как улучшить модель на этих объектах?

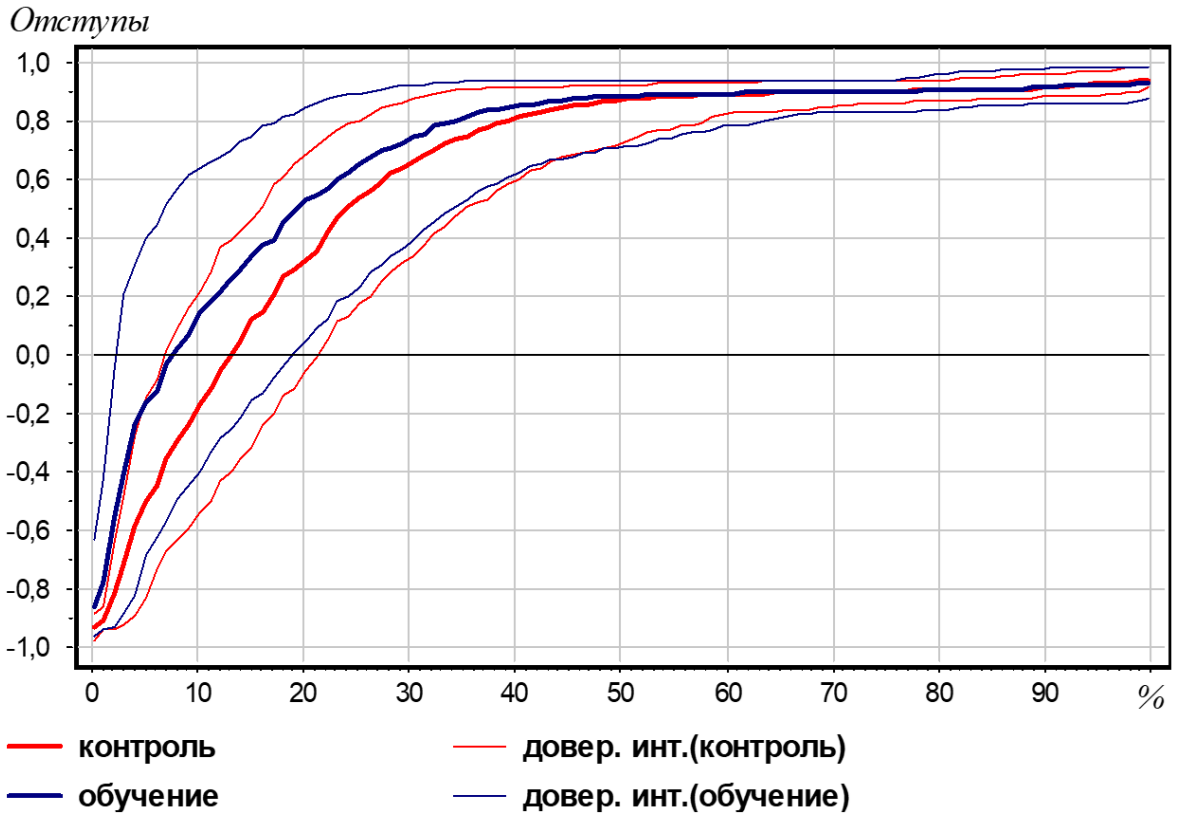
Сравнительный анализ потерь на обучении и тесте:

- Сильно ли отличаются распределения потерь?
- Если сильно, то как устранить переобучение?

Анализ распределения отступов в задаче классификации

Вместо потерь $\mathscr{L}_i = L(M_i)$ можно ранжировать отступы M_i

Видно: переобучение, зону неуверенной классификации

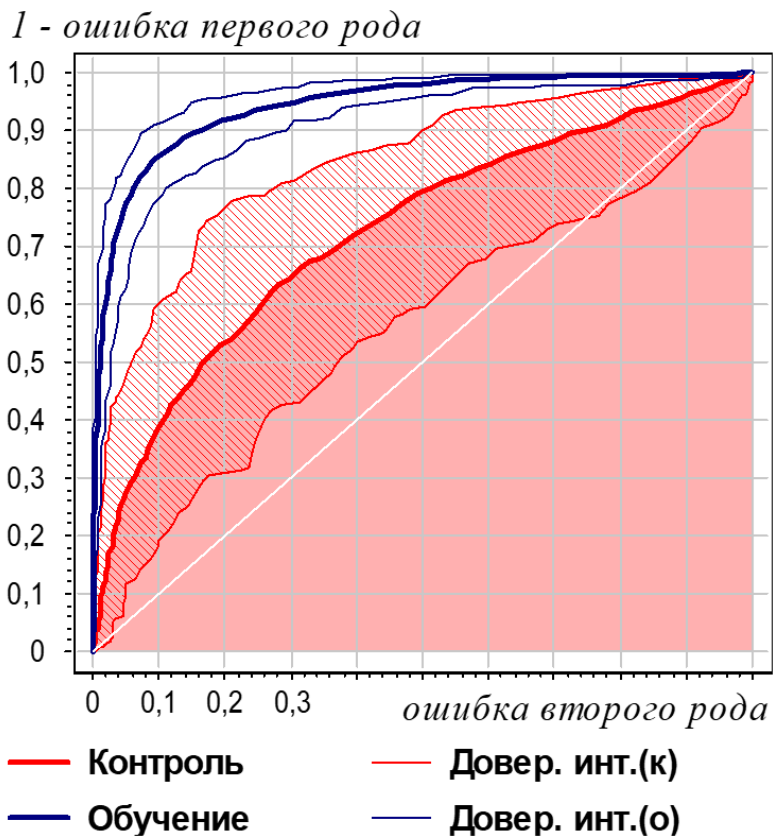


Задача UCI:australian, метод JRip

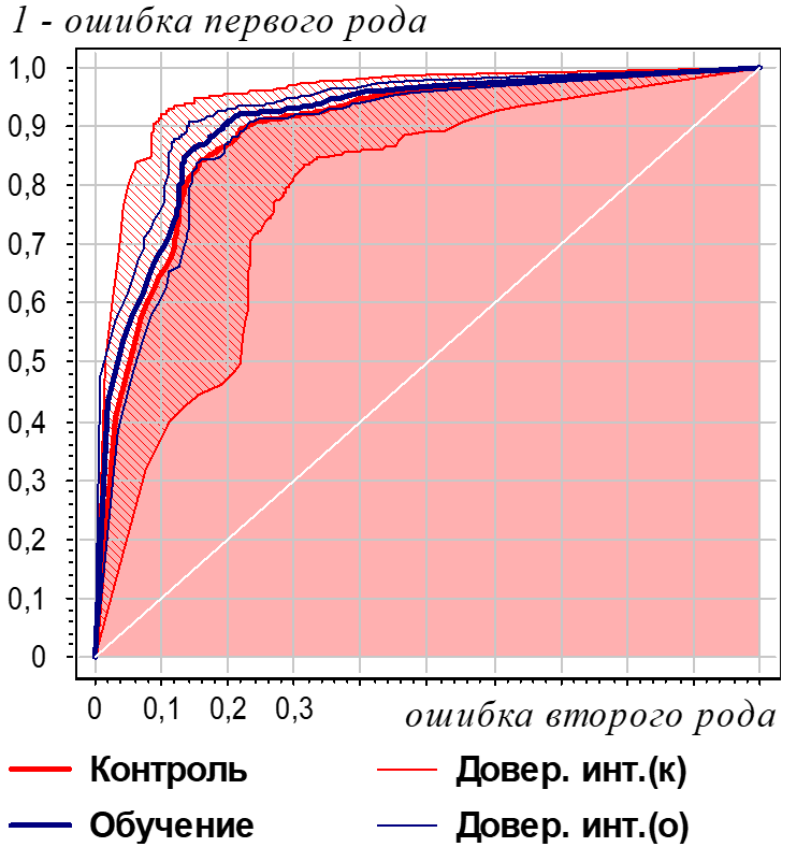
Анализ ROC-кривых

ROC-кривые можно строить отдельно для каждого класса

Видно: переобучение, устойчивость, различия классов



Задача UCI:liver, метод Bagging



Задача UCI:heart, метод Naïve Bayes

A/B тестирование (A/B testing, Split Testing)

Две модели, «базовая A» и «улучшенная B»,
построенные по историческим данным X^ℓ,
тестируются по метрике качества Q на новых данных X^k

В чём отличия A/B тестирования от обычного hold-out?

- X^k — это именно будущие данные (out-of-time), а не часть прошлых данных, исключённых из обучения (out-of-sample)
- больше реализма: за это время могут измениться свойства потока данных, реальные данные не обязаны быть i.i.d.
- однократный выбор модели почти не переобучается
- накопление данных X^k может потребовать много времени
- работа модели может влиять на формирование потока данных (например, в рекомендательных системах)

Автоматический выбор моделей и гиперпараметров (AutoML)

Проблема:
подбор структуры модели (архитектуры нейросети)
и гиперпараметров требует слишком много ресурсов

Дано: выборка «задача, структура» $\to$ критерии качества

Найти: какой следующий эксперимент провести с моделью

Критерий:
минимизация затрат ресурсов на автоматический поиск оптимальной модели, сопоставимой по качеству с моделями, построенными профессиональными исследователями

Близкая классическая задача — *планирование экспериментов*

Xin He et al. AutoML: A Survey of the State-of-the-Art. 2019

https://github.com/sberbank-ai-lab/LightAutoML — AutoML от Сбербанка

Мета-обучение (meta-learning, learning to learn)

Проблема: слишком много методов, слишком долго запускать

Дано: выборка «задача, метод» $\to$ критерии качества

Найти: модель многоклассовой классификации / ранжирования, предсказывающую, какими методами лучше решать задачу

Критерий: точность предсказания оптимального метода

Признаки:

- размерные характеристики задачи
- характеристики пространства признаков: типы, выбросы, пропуски, корреляции
- результаты быстрых низкоразмерных методов

Joaquin Vanschoren. Meta-learning Architectures: Collecting, Organizing and Exploiting Meta-knowledge. 2009.

Joaquin Vanschoren. Meta-Learning: A Survey. 2018.

Резюме. Анализ ошибок и выбор моделей

- Культура анализа данных:
  — смотреть на данные глазами
  — пробовать нетривиальные идеи предобработки, основанные на знаниях предметной области
  — использовать анализ ошибок и визуализацию
  — креативно порождать и оценивать больше гипотез
  — знать и учитывать сильные и слабые стороны методов
- Автоматизация распространяется по схеме CRISP-DM, в перспективе нас ожидает бесшовная интеграция этапов
  — предобработки данных
  — моделирования
  — оценивания и выбора моделей
  — внедрения