Методы машинного обучения. Метод опорных векторов

Воронцов Константин Вячеславович
www.MachineLearning.ru/wiki?title=User:Vokov
вопросы к лектору: vorontsovkv@my.msu.ru

материалы курса:
github.com/MSU-ML-COURSE/ML-COURSE-26-27
орг.вопросы по курсу: ml.cmc@mail.ru

ВМК МГУ • 13 октября 2026

Содержание

1. **Метод опорных векторов SVM**
   - Принцип оптимальной разделяющей гиперплоскости
   - Двойственная задача
   - Понятие опорного вектора
2. **Обобщения линейного SVM**
   - Ядра и спрямляющие пространства
   - Вероятностная калибровка
   - SVM-регрессия
3. **Регуляризация**
   - Подбор коэффициента регуляризации
   - Регуляризаторы для отбора признаков
   - Метод релевантных векторов RVM

Задача обучения линейного бинарного классификатора

Дано:

Обучающая выборка $X^\ell = (x_i, y_i)_{i=1}^\ell$, $x_i \in \mathbb{R}^n$, $y_i \in \{-1, +1\}$

Найти:

Параметры $w \in \mathbb{R}^n$, $w_0 \in \mathbb{R}$ линейной модели классификации

$$a(x; w, w_0) = \operatorname{sign}\big(\langle x, w\rangle - w_0\big) = \operatorname{sign}\Big(\sum_{j=1}^n w_j f_j(x) - w_0\Big)$$

Критерий — минимум эмпирического риска:

$$\sum_{i=1}^\ell \big[a(x_i; w, w_0) \neq y_i\big] = \sum_{i=1}^\ell \big[M_i(w, w_0) < 0\big] \;\to\; \min_{w, w_0},$$

где $M_i(w, w_0) = \big(\langle x_i, w\rangle - w_0\big) y_i$ — *отступ* (margin) объекта x_i

---

В. Н. Вапник, А. Я. Лернер. Узнавание образов при помощи обобщенных портретов. 1963.

C. Cortes, V. Vapnik. Support vector networks. 1995.

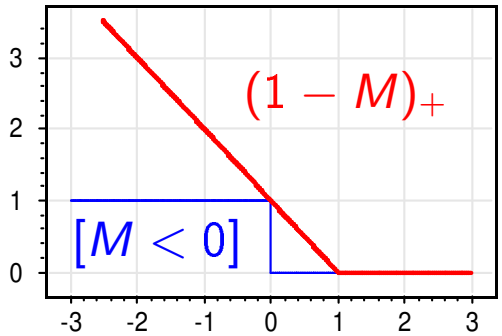
Аппроксимация и регуляризация эмпирического риска

Эмпирический риск — это кусочно-постоянная функция
Заменим его оценкой сверху, непрерывной по параметрам:

$$Q(w, w_0) = \sum_{i=1}^{\ell} \big[M_i(w, w_0) < 0\big] \leqslant$$

$$\leqslant \sum_{i=1}^{\ell} \big(1 - M_i(w, w_0)\big)_+ + \frac{1}{2C}\|w\|^2 \to \min_{w, w_0}$$

- *Аппроксимация* штрафует объекты за приближение к границе классов, увеличивая зазор между классами
- *Регуляризация* штрафует неустойчивые решения в случае мультиколлинеарности



В. Н. Вапник, А. Я. Лернер. Узнавание образов при помощи обобщенных портретов. 1963.
C. Cortes, V. Vapnik. Support vector networks. 1995.

Оптимальная разделяющая гиперплоскость

Линейный классификатор: $a(x, w) = \text{sign}\big(\langle w, x\rangle - w_0\big)$

Пусть выборка $X^\ell = (x_i, y_i)_{i=1}^\ell$ линейно разделима:

$$\exists w, w_0: \quad M_i(w, w_0) = y_i\big(\langle w, x_i\rangle - w_0\big) > 0, \quad i = 1, \ldots, \ell$$

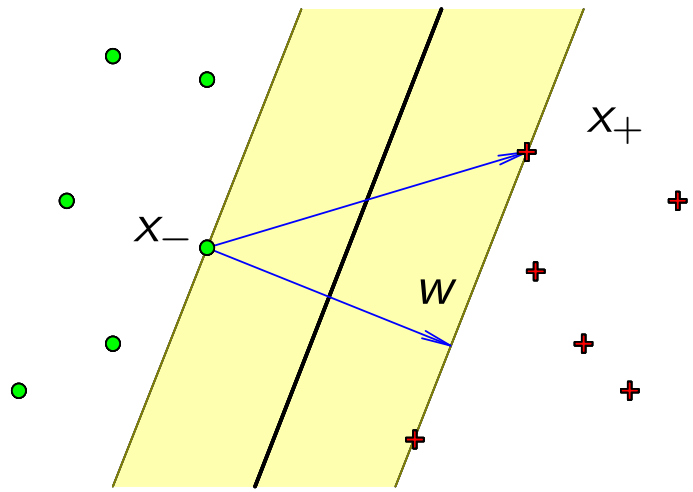
Нормировка: $\min\limits_{i=1,\ldots,\ell} M_i(w, w_0) = 1$

Разделяющая полоса (разделяющая гиперплоскость посередине):

$$\big\{x: \ -1 \leqslant \langle w, x\rangle - w_0 \leqslant 1\big\}$$

$$\exists x_+: \quad \langle w, x_+\rangle - w_0 = +1$$

$$\exists x_-: \quad \langle w, x_-\rangle - w_0 = -1$$



Ширина полосы:

$$\frac{\langle x_+ - x_-, w\rangle}{\|w\|} = \frac{2}{\|w\|} \to \max$$

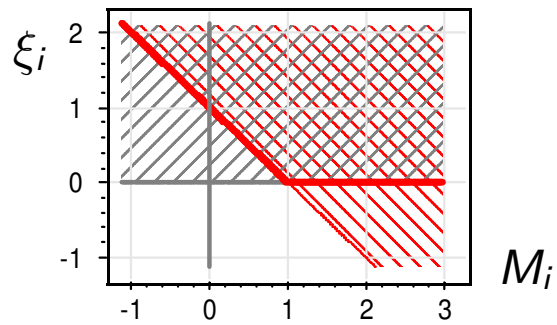
Обоснование кусочно-линейной функции потерь

Линейно разделимая выборка

$$\begin{cases} \frac{1}{2}\|w\|^2 \to \min\limits_{w,w_0} \\ M_i(w,w_0) \geqslant 1, \quad i = 1,\ldots,\ell \end{cases}$$

Переход к линейно неразделимой выборке (эвристика)

$$\begin{cases} \frac{1}{2}\|w\|^2 + C\sum\limits_{i=1}^{\ell}\xi_i \to \min\limits_{w,w_0,\xi} \\ \xi_i \geqslant 1 - M_i(w,w_0), \quad i = 1,\ldots,\ell \\ \xi_i \geqslant 0, \quad i = 1,\ldots,\ell \end{cases}$$



Эквивалентная задача безусловной минимизации:

$$C\sum_{i=1}^{\ell}\big(1 - M_i(w,w_0)\big)_+ + \frac{1}{2}\|w\|^2 \to \min_{w,w_0}$$

Напоминание. Условия Каруша–Куна–Таккера (ККТ)

Задача математического программирования:

$$\begin{cases} f(x) \to \min\limits_x \\ g_i(x) \leqslant 0, \quad i = 1, \ldots, m \\ h_j(x) = 0, \quad j = 1, \ldots, k \end{cases}$$

Необходимые условия. Если x — точка локального минимума, то существуют множители μ_i, $i = 1, \ldots, m$, λ_j, $j = 1, \ldots, k$:

$$\begin{cases} \dfrac{\partial \mathscr{L}}{\partial x} = 0, \quad \mathscr{L}(x; \mu, \lambda) = f(x) + \sum\limits_{i=1}^{m} \mu_i g_i(x) + \sum\limits_{j=1}^{k} \lambda_j h_j(x) \\ g_i(x) \leqslant 0; \;\; h_j(x) = 0 \;\; \text{(исходные ограничения)} \\ \mu_i \geqslant 0 \;\; \text{(двойственные ограничения)} \\ \mu_i g_i(x) = 0 \;\; \text{(условие дополняющей нежёсткости)} \end{cases}$$

Применение условий ККТ к задаче SVM

Функция Лагранжа: $\mathscr{L}(w, w_0, \xi; \lambda, \eta) =$

$$= \frac{1}{2}\|w\|^2 - \sum_{i=1}^{\ell} \lambda_i \big(M_i(w, w_0) - 1\big) - \sum_{i=1}^{\ell} \xi_i \big(\lambda_i + \eta_i - C\big)$$

λ_i — переменные, двойственные к ограничениям $M_i \geqslant 1 - \xi_i$

η_i — переменные, двойственные к ограничениям $\xi_i \geqslant 0$

$$\begin{cases} \dfrac{\partial \mathscr{L}}{\partial w} = 0, \quad \dfrac{\partial \mathscr{L}}{\partial w_0} = 0, \quad \dfrac{\partial \mathscr{L}}{\partial \xi} = 0 \\ \xi_i \geqslant 0, \quad \lambda_i \geqslant 0, \quad \eta_i \geqslant 0, \quad i = 1, \ldots, \ell \\ \lambda_i = 0 \;\text{ либо }\; M_i(w, w_0) = 1 - \xi_i, \quad i = 1, \ldots, \ell \\ \eta_i = 0 \;\text{ либо }\; \xi_i = 0, \quad i = 1, \ldots, \ell \end{cases}$$

Необходимые условия седловой точки функции Лагранжа

Функция Лагранжа: $\mathscr{L}(w, w_0, \xi; \lambda, \eta) =$

$$= \frac{1}{2}\|w\|^2 - \sum_{i=1}^{\ell} \lambda_i \big(M_i(w, w_0) - 1\big) - \sum_{i=1}^{\ell} \xi_i \big(\lambda_i + \eta_i - C\big)$$

Необходимые условия седловой точки функции Лагранжа:

$$\frac{\partial \mathscr{L}}{\partial w} = w - \sum_{i=1}^{\ell} \lambda_i y_i x_i = 0 \quad \Longrightarrow \quad w = \sum_{i=1}^{\ell} \lambda_i y_i x_i$$

$$\frac{\partial \mathscr{L}}{\partial w_0} = -\sum_{i=1}^{\ell} \lambda_i y_i = 0 \quad \Longrightarrow \quad \sum_{i=1}^{\ell} \lambda_i y_i = 0$$

$$\frac{\partial \mathscr{L}}{\partial \xi_i} = -\lambda_i - \eta_i + C = 0 \quad \Longrightarrow \quad \eta_i + \lambda_i = C, \quad i = 1, \ldots, \ell$$

Понятие опорного вектора и типизация объектов

Система условий KKT:

$$\begin{cases} w = \sum\limits_{i=1}^{\ell} \lambda_i y_i x_i; \quad \sum\limits_{i=1}^{\ell} \lambda_i y_i = 0; \quad M_i(w, w_0) \geqslant 1 - \xi_i \\ \xi_i \geqslant 0, \quad \lambda_i \geqslant 0, \quad \eta_i \geqslant 0, \quad \eta_i + \lambda_i = C \\ \lambda_i = 0 \;\text{ либо }\; M_i(w, w_0) = 1 - \xi_i \\ \eta_i = 0 \;\text{ либо }\; \xi_i = 0 \end{cases}$$

Определение. Объект x_i называется *опорным*, если $\lambda_i \neq 0$

Типизация объектов x_i, $i = 1, \ldots, \ell$:

1. $\lambda_i = 0$; $\eta_i = C$; $\xi_i = 0$; $M_i \geqslant 1$ — периферийный
2. $0 < \lambda_i < C$; $0 < \eta_i < C$; $\xi_i = 0$; $M_i = 1$ — опорный-граничный
3. $\lambda_i = C$; $\eta_i = 0$; $\xi_i > 0$; $M_i < 1$ — опорный-нарушитель

Двойственная задача

$$\begin{cases} -\mathscr{L}(\lambda) = -\sum\limits_{i=1}^{\ell} \lambda_i + \frac{1}{2}\sum\limits_{i=1}^{\ell}\sum\limits_{j=1}^{\ell} \lambda_i\lambda_j y_i y_j \langle x_i, x_j\rangle \;\to\; \min\limits_{\lambda} \\ \sum\limits_{i=1}^{\ell} \lambda_i y_i = 0; \qquad 0 \leqslant \lambda_i \leqslant C, \quad i = 1, \ldots, \ell \end{cases}$$

Решение прямой задачи выражается через решение двойственной:

$$\begin{cases} w = \sum\limits_{i=1}^{\ell} \lambda_i y_i x_i \\ w_0 = \langle w, x_i\rangle - y_i, \qquad \text{для любого } i\text{: } \lambda_i > 0,\ M_i = 1 \end{cases}$$

Линейный классификатор с признаками $f_i(x) = \langle x, x_i\rangle$:

$$a(x) = \operatorname{sign}\Big(\sum_{i=1}^{\ell} \lambda_i y_i \langle x, x_i\rangle - w_0 \Big)$$

S.Fine, K.Scheinberg. INCAS: An incremental active set method for SVM. 2002.
J.Platt. Fast training support vector machines using sequential minimal optimization. 1999.

Двойственная задача. Нелинейное обобщение с ядром K

$$\begin{cases} -\mathscr{L}(\lambda) = -\sum\limits_{i=1}^{\ell} \lambda_i + \frac{1}{2} \sum\limits_{i=1}^{\ell} \sum\limits_{j=1}^{\ell} \lambda_i \lambda_j y_i y_j K(x_i, x_j) \;\to\; \min\limits_{\lambda} \\ \sum\limits_{i=1}^{\ell} \lambda_i y_i = 0; \qquad 0 \leqslant \lambda_i \leqslant C, \quad i = 1, \ldots, \ell \end{cases}$$

Решение прямой задачи выражается через решение двойственной:

$$\begin{cases} w = \sum\limits_{i=1}^{\ell} \lambda_i y_i x_i \\ w_0 = \langle w, x_i \rangle - y_i, \qquad \text{для любого } i\text{: } \lambda_i > 0,\ M_i = 1 \end{cases}$$

Линейный классификатор с признаками $f_i(x) = K(x, x_i)$:

$$a(x) = \operatorname{sign}\left(\sum_{i=1}^{\ell} \lambda_i y_i K(x, x_i) - w_0 \right)$$

S.Fine, K.Scheinberg. INCAS: An incremental active set method for SVM. 2002.
J.Platt. Fast training support vector machines using sequential minimal optimization. 1999.

Нелинейное обобщение SVM

Идея: заменить $\langle x, x' \rangle$ нелинейной функцией $K(x, x')$

Переход к спрямляющему пространству,
как правило, более высокой размерности: $\psi\colon X \to H$

Определение

Функция $K\colon X \times X \to \mathbb{R}$ — *ядро*, если $K(x, x') = \langle \psi(x), \psi(x') \rangle$ при некотором $\psi\colon X \to H$, где H — гильбертово пространство

Теорема

Функция $K(x, x')$ является ядром тогда и только тогда, когда
она симметрична: $K(x, x') = K(x', x)$
и неотрицательно определена:
$\int_X \int_X K(x, x') g(x) g(x') dx dx' \geqslant 0$ для любой $g\colon X \to \mathbb{R}$

Конструктивные методы синтеза ядер

1. $K(x, x') = \langle x, x' \rangle$ — ядро
2. константа $K(x, x') = 1$ — ядро
3. произведение ядер $K(x, x') = K_1(x, x')K_2(x, x')$ — ядро
4. $\forall \psi : X \to \mathbb{R}$ произведение $K(x, x') = \psi(x)\psi(x')$ — ядро
5. $K(x, x') = \alpha_1 K_1(x, x') + \alpha_2 K_2(x, x')$ при $\alpha_1, \alpha_2 > 0$ — ядро
6. $\forall \varphi : X \to X$ если K_0 ядро, то $K(x, x') = K_0(\varphi(x), \varphi(x'))$ — ядро
7. если $s\colon X \times X \to \mathbb{R}$ — симметричная интегрируемая функция, то $K(x, x') = \int_X s(x, z)s(x', z)\, dz$ — ядро
8. если K_0 — ядро и функция $f : \mathbb{R} \to \mathbb{R}$ представима в виде сходящегося степенного ряда с неотрицательными коэффициентами, то $K(x, x') = f\big(K_0(x, x')\big)$ — ядро

Пример: спрямляющее пространство для квадратичного ядра

Пусть $X = \mathbb{R}^2$, $K(u,v) = \langle u,v\rangle^2$, где $u = (u_1,u_2)$, $v = (v_1,v_2)$

Задача: найти пространство H и преобразование $\psi\colon X \to H$, при которых $K(x,x') = \langle \psi(x), \psi(x')\rangle_H$

Разложим квадрат скалярного произведения:

$$\begin{aligned} K(u,v) = \langle u,v\rangle^2 &= \langle (u_1,u_2),(v_1,v_2)\rangle^2 = \\ &= (u_1v_1 + u_2v_2)^2 = u_1^2v_1^2 + u_2^2v_2^2 + 2u_1v_1u_2v_2 = \\ &= \langle (u_1^2, u_2^2, \sqrt{2}u_1u_2), (v_1^2, v_2^2, \sqrt{2}v_1v_2)\rangle \end{aligned}$$

Таким образом,

$$H = \mathbb{R}^3, \quad \psi\colon (u_1,u_2) \mapsto \left(u_1^2, u_2^2, \sqrt{2}u_1u_2\right),$$

линейной поверхности в пространстве H соответствует квадратичная поверхность в исходном пространстве X

Примеры ядер

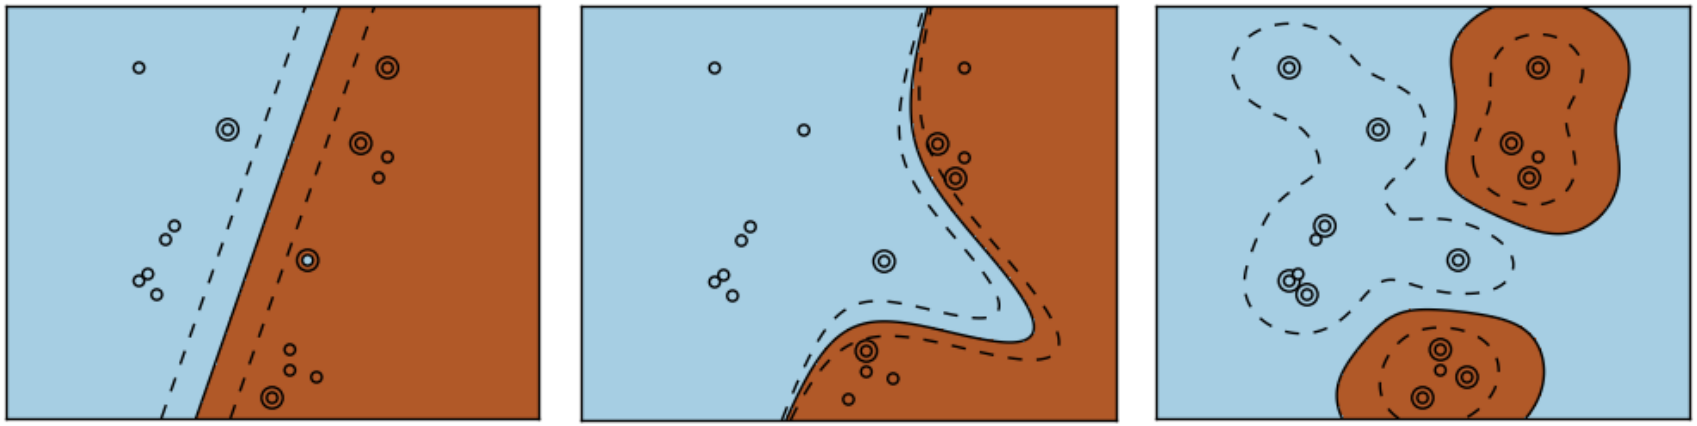
1. квадратичное ядро, $X = \mathbb{R}^n$, $\dim H = \frac{1}{2}n(n+1) = C_{n+1}^2$
   $K(x, x') = \langle x, x' \rangle^2$
2. полиномиальное с мономами степени d, $\dim H = C_{n+d-1}^d$
   (число мономов вида $u_1^{d_1} \cdots u_n^{d_n}$, где $\sum_{j=1}^n d_j = d$, равно числу размещений с повторениями d одинаковых шаров по n ящикам)
   $K(x, x') = \langle x, x' \rangle^d$
3. полиномиальное с мономами степеней $0..d$, $\dim H = C_{n+d}^d$
   (к n ящикам-признакам добавляется ящик с константой 1)
   $K(x, x') = \big(\langle x, x' \rangle + 1\big)^d$
4. линейный нейрон с сигмоидной функцией активации
   $K(x, x') = \operatorname{th}\big(k_1 \langle x, x' \rangle - k_0\big), \quad k_0, k_1 \geqslant 0$
5. радиальная базисная функция (RBF ядро)
   $K(x, x') = \exp\big(-\gamma \|x - x'\|^2\big)$

Классификация с различными ядрами

Гиперплоскость в спрямляющем пространстве H соответствует нелинейной разделяющей поверхности в исходном X

Примеры с различными ядрами $K(x, x')$:

линейное	полиномиальное	гауссовское (RBF)
$\langle x, x' \rangle$	$\big(\langle x, x' \rangle + 1\big)^d, \quad d{=}3$	$\exp\big(-\gamma \|x - x'\|^2\big)$

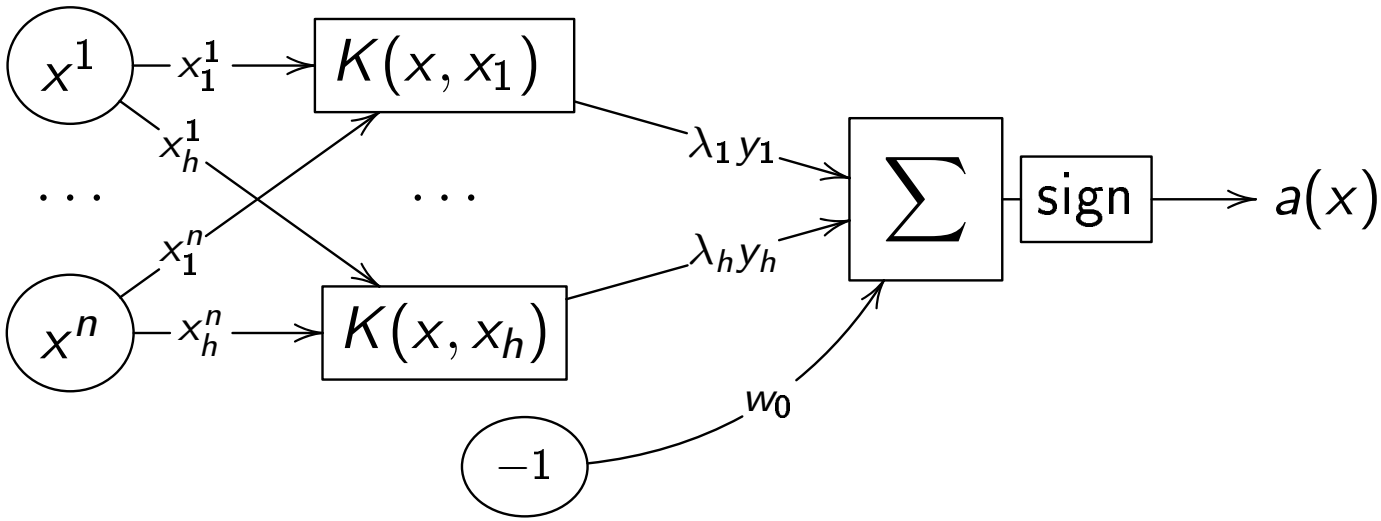


Пример из Python SkLearn: `http://scikit-learn.org/dev`

SVM — двухслойная нейросеть и метрический классификатор

Перенумеруем объекты так, чтобы $x_1, \ldots, x_h$ были опорными

$$a(x) = \text{sign}\left(\sum_{i=1}^{h} \lambda_i y_i K(x, x_i) - w_0\right)$$



Первый слой вместо скалярных произведений вычисляет ядра

Число нейронов в первом слое равно числу опорных векторов

Веса первого слоя — это сами опорные объекты

Метрический классификатор, если K — функция близости

Преимущества и недостатки SVM

Преимущества перед двухслойными нейронными сетями:

- задача выпуклого квадратичного программирования имеет единственное решение
- число нейронов скрытого слоя определяется автоматически — это число опорных векторов

Недостатки классического SVM (некоторые устранимы):

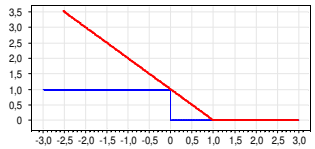
- нет общих подходов к оптимизации $K(x, x')$ под задачу
- на больших данных SVM обучается медленнее SG
- нет «вероятностного выхода» $p(y|x)$ как в лог-регрессии
- приходится подбирать константу C
- нет «встроенного» отбора признаков
- шумовые объекты (выбросы) являются опорными

SVM и регуляризованная логистическая регрессия

$a(x; w, w_0) = \text{sign}\big(\langle x, w\rangle - w_0\big)$ — линейная модель классификации
$M_i = (\langle x_i, w\rangle - w_0)y_i$ — отступ объекта x_i обучающей выборки

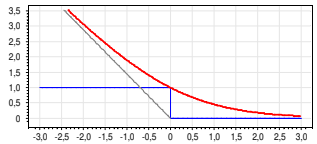
Критерий SVM (ERM с аппроксимацией и регуляризацией):

$$\sum_{i=1}^{\ell}(1 - M_i)_+ + \frac{1}{2C}\|w\|^2 \to \min_{w,w_0}$$



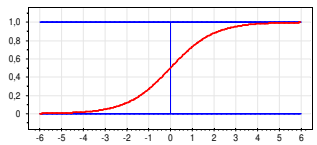
Критерий RLR (регуляризованная лог-регрессия):

$$\sum_{i=1}^{\ell}\ln\big(1 + e^{-M_i}\big) + \frac{\tau}{2}\|w\|^2 \to \min_{w,w_0}$$



Логистическая регрессия имеет probabilistic output:

$$P(y|x, w) = \sigma\big((\langle x, w\rangle - w_0)y\big), \quad \sigma(M) = \frac{1}{1+e^{-M}}$$



Как в SVM оценивать апостериорные вероятности классов?

Напоминание. Вероятностная калибровка Платта

Дано: выборка $(x_i, y_i)_{i=1}^{\ell}$, $y_i \in \{-1, +1\}$;
обученный разделяющий классификатор $a(x) = \operatorname{sign} b(x)$,
исходно не имеющий вероятностной интерпретации.

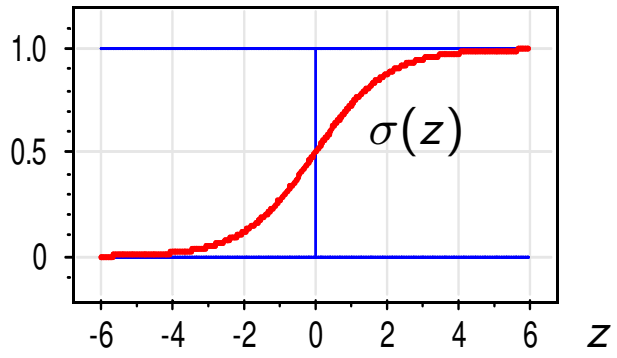
Найти: вероятностную модель классификации $\mathrm{P}(y|x)$

лог-регрессия на одном признаке $b(x)$

$$\pi(x; \kappa, \delta) = \mathrm{P}(y=1|x) = \sigma\big(\kappa b(x) + \delta\big)$$

где $\sigma(z) = \frac{1}{1+e^{-z}}$ — сигмоидная функция

важное её свойство: $\sigma(-z) = 1 - \sigma(z)$



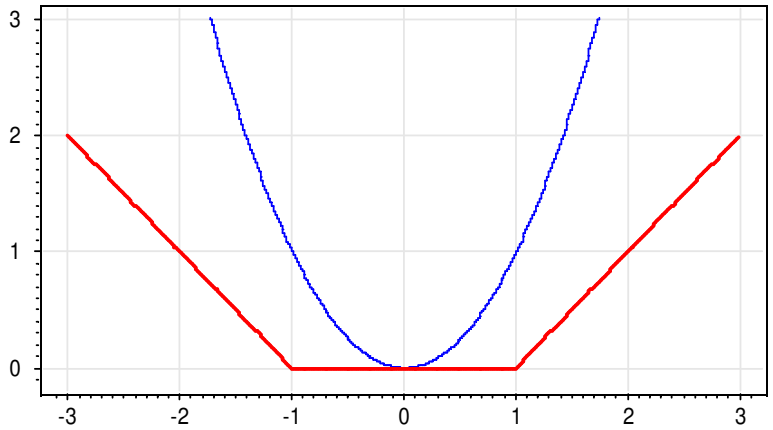
Критерий: максимум log-правдоподобия для калибровки коэффициентов κ, δ по *контрольной* выборке (hold-out):

$$\sum_{y_i=-1} \ln\big(1 - \pi(x_i; \kappa, \delta)\big) + \sum_{y_i=+1} \ln \pi(x_i; \kappa, \delta) \to \max_{\kappa,\delta}$$

SVM-регрессия

Модель регрессии: $a(x, w) = \langle x, w \rangle - w_0, \quad w \in \mathbb{R}^n, \quad w_0 \in \mathbb{R}$

Функции потерь: $\mathscr{L}(\varepsilon) = \varepsilon^2, \quad \mathscr{L}(\varepsilon) = \big(|\varepsilon| - \delta\big)_+, \quad \varepsilon = a - y$



Постановка задачи:

$$\sum_{i=1}^{\ell} \big(|\langle w, x_i \rangle - w_0 - y_i| - \delta\big)_+ + \frac{1}{2C}\|w\|^2 \to \min_{w, w_0}$$

Задача решается путём замены переменных
и сведения к задаче квадратичного программирования

SVM-регрессия

Замена переменных:

$$\xi_i^+ = (\langle w, x_i \rangle - w_0 - y_i - \delta)_+$$
$$\xi_i^- = (-\langle w, x_i \rangle + w_0 + y_i - \delta)_+$$

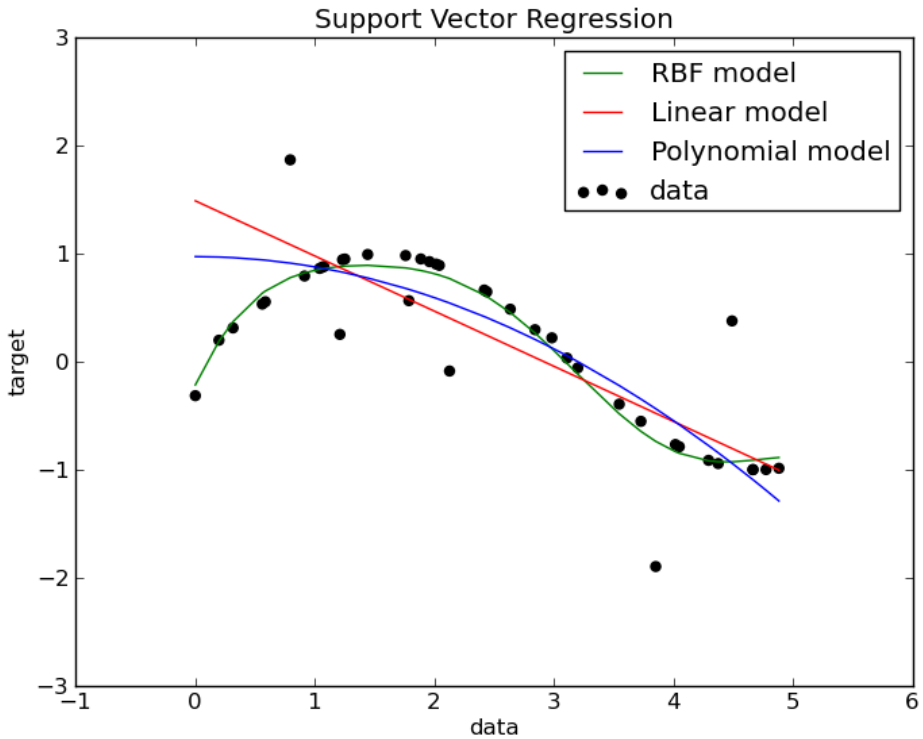
Постановка задачи SVM-регрессии:

$$\begin{cases} \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{\ell}(\xi_i^+ + \xi_i^-) \to \min\limits_{w, w_0, \xi^+, \xi^-} \\ y_i - \delta - \xi_i^- \leqslant \langle w, x_i \rangle - w_0 \leqslant y_i + \delta + \xi_i^+, \quad i = 1, \ldots, \ell \\ \xi_i^- \geqslant 0, \quad \xi_i^+ \geqslant 0, \quad i = 1, \ldots, \ell \end{cases}$$

- выпуклая задача квадратичного программирования
- следовательно, решение единственное
- решение разреженное, выражается через опорные векторы
- возможна замена $\langle x, x_i \rangle$ ядром $K(x, x_i)$

SVM-регрессия. Пример 1

Сравнение SVM-регрессии с гауссовским (RBF) ядром, линейной и полиномиальной регрессией:



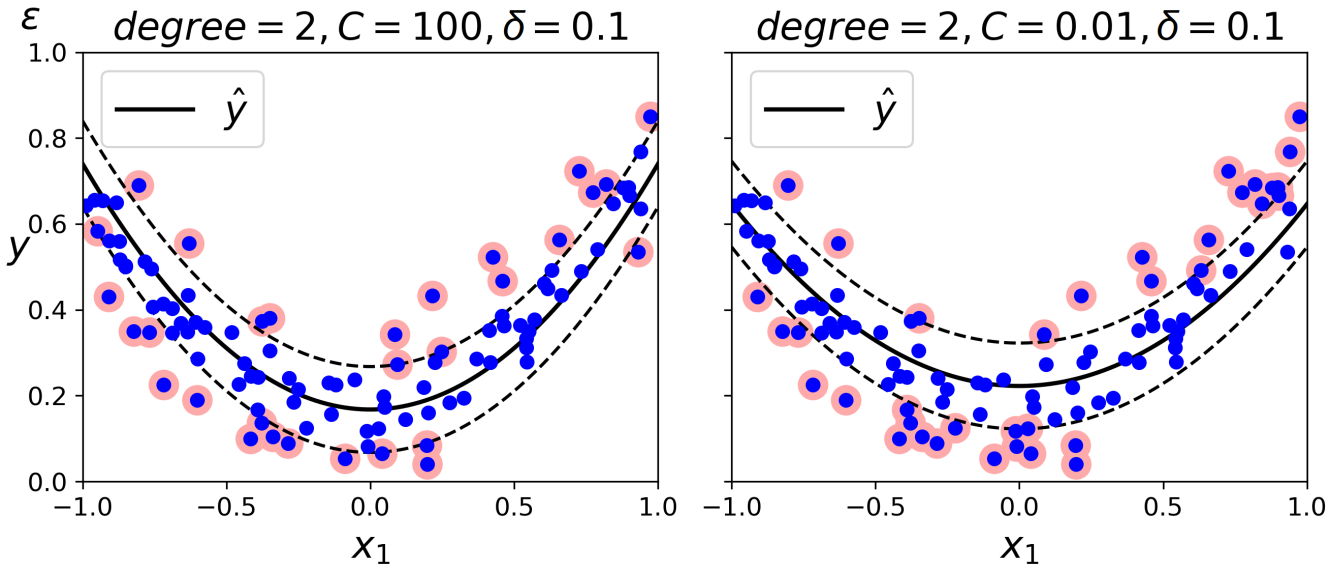
- Удачный выбор ядра имеет значение!

---

http://scikit-learn.org/0.5/auto_examples/svm/plot_svm_regression.html

SVM-регрессия. Пример 2

SVM-регрессия с полиномиальным ядром степени 2:



- Выделены опорные векторы
- Результат обучения устойчив к выбору константы C

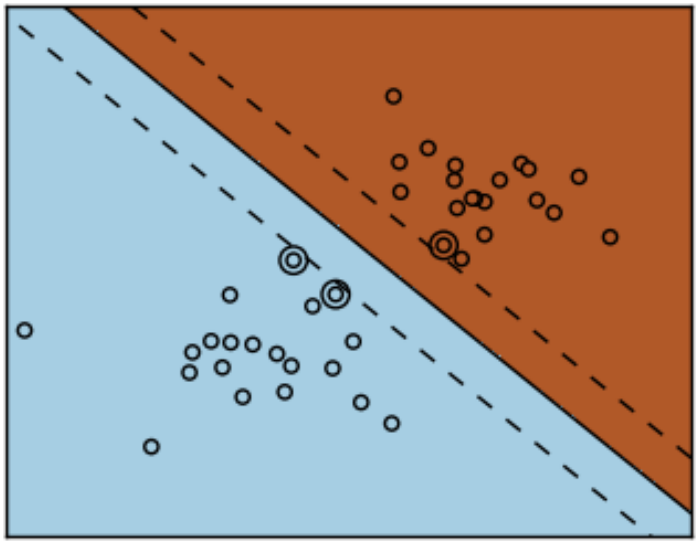
http://scikit-learn.org/0.5/auto_examples/svm/plot_svm_regression.html

Влияние константы C на решение SVM

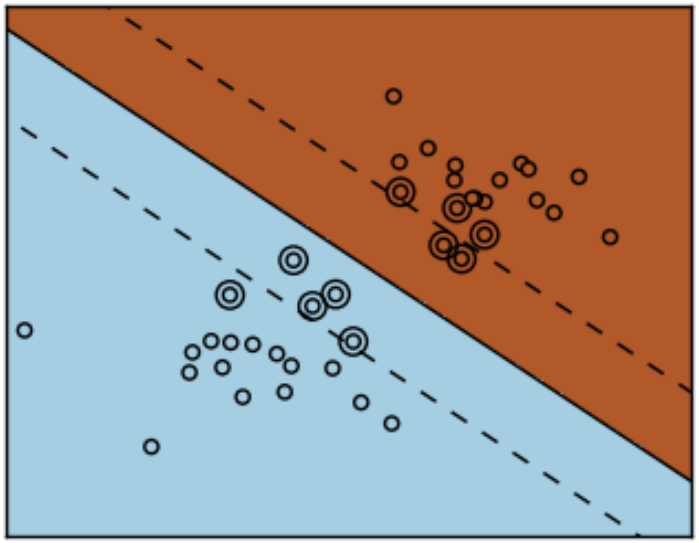
SVM — аппроксимация и регуляризация эмпирического риска:

$$\sum_{i=1}^{\ell}\big(1 - M_i(w, w_0)\big)_+ + \frac{1}{2C}\|w\|^2 \;\to\; \min_{w, w_0}$$

слабая регуляризация:
большой $C \Rightarrow$ узкая полоса



сильная регуляризация:
малый $C \Rightarrow$ широкая полоса



- Результат обучения устойчив к выбору константы C

Пример из Python SkLearn: `http://scikit-learn.org/dev`

1-norm SVM (LASSO SVM)

Аппроксимация эмпирического риска с L_1-регуляризацией:

$$\sum_{i=1}^{\ell}\big(1 - M_i(w, w_0)\big)_+ + \mu\sum_{j=1}^{n}|w_j| \;\to\; \min_{w,w_0}$$

Почему L_1-регуляризатор приводит к отбору признаков?

Замена переменных: $u_j = \frac{1}{2}\big(|w_j| + w_j\big)$, $v_j = \frac{1}{2}\big(|w_j| - w_j\big)$.
Тогда $w_j = u_j - v_j$ и $|w_j| = u_j + v_j$;

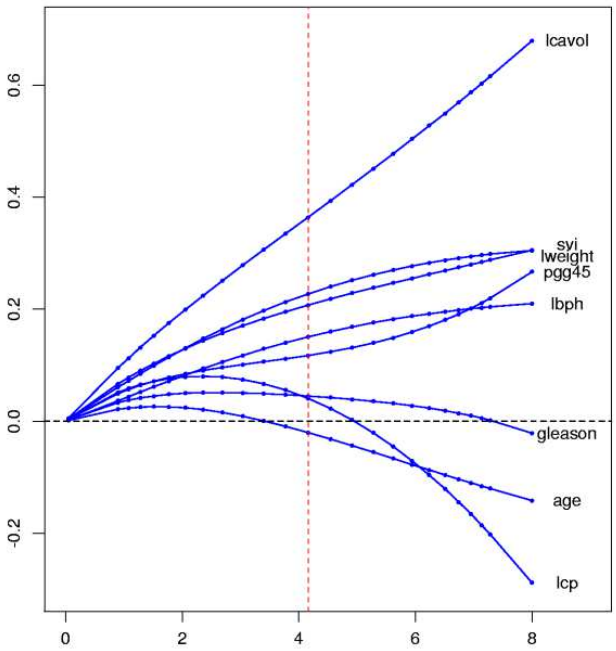
$$\begin{cases} \sum_{i=1}^{\ell}\big(1 - M_i(u - v, w_0)\big)_+ + \mu\sum_{j=1}^{n}(u_j + v_j) \to \min_{u,v} \\ u_j \geqslant 0, \quad v_j \geqslant 0, \quad j = 1, \ldots, n \end{cases}$$

чем больше μ, тем больше индексов j таких, что $u_j = v_j = 0$,
но тогда $w_j = 0$, значит, признак не учитывается

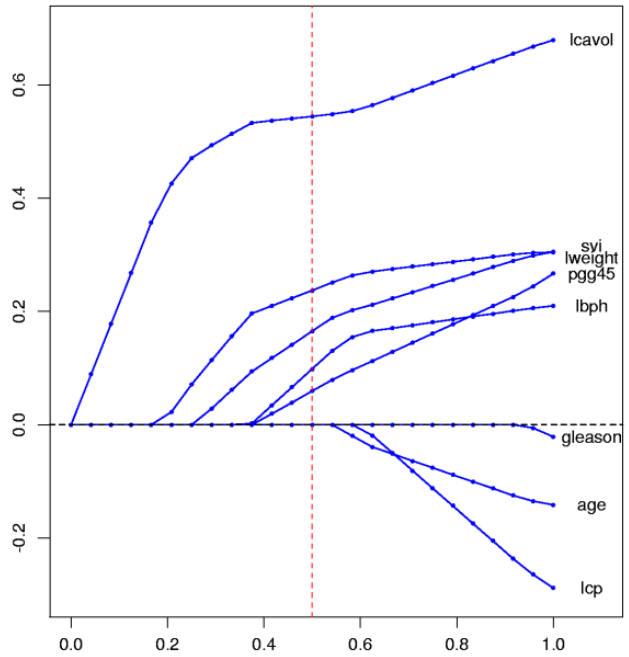
Сравнение L_2 и L_1 регуляризации

Зависимость весов w_j от коэффициента $\frac{1}{\mu}$

L_2 регуляризатор: $\mu \sum_j w_j^2$



L_1 регуляризатор: $\mu \sum_j |w_j|$



Задача из UCI: prostate cancer (диагностика рака)

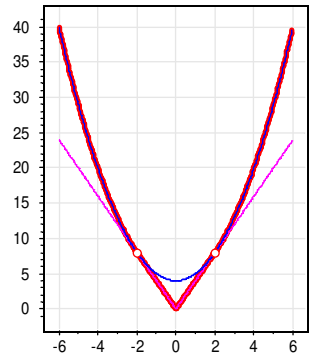
T.Hastie, R.Tibshirani, J.Friedman. The Elements of Statistical Learning. 2001.

Напоминание. Негладкие регуляризаторы для отбора признаков

Общий вид регуляризаторов (μ — параметр селективности):

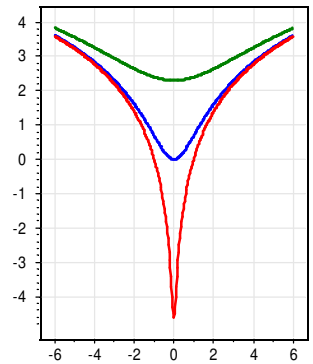
$$\sum_{i=1}^{\ell}\big(1 - M_i(w, w_0)\big)_+ + \sum_{j=1}^{n} R_\mu(w_j) \;\to\; \min_w$$

LASSO (L_1): $R_\mu(w) = \mu|w|$
— отбрасывает мультиколлинеарные признаки



Elastic Net: $R_{\mu,\tau}(w) = \mu|w| + \tau\frac{1}{2}w^2$
— группирует совместно значимые признаки

Support Feature Machine (SFM):
$R_\mu(w) = \big[|w| \leqslant \mu\big] \cdot 2\mu|w| + \big[|w| > \mu\big] \cdot (\mu^2 + w^2)$
— группирует, отбрасывая незначимые признаки



Relevance Feature Machine (RFM):
$R_\mu(w) = \ln\big(\mu w^2 + 1\big)$
— точнее находит совместно значимые признаки

Метод релевантных векторов RVM (Relevance Vector Machine)

Положим, как и в SVM, при некоторых $\lambda_i \geqslant 0$

$$w = \sum_{i=1}^{\ell} \lambda_i y_i x_i,$$

причём опорным векторам x_i соответствуют $\lambda_i \neq 0$

Проблема: Какие из коэффициентов λ_i лучше обнулить?

Идея: пусть регуляризатор зависит не от w, а от λ_i,
и пусть λ_i независимые, гауссовские, с дисперсиями α_i:

$$p(\lambda) = \frac{1}{(2\pi)^{\ell/2}\sqrt{\alpha_1 \cdots \alpha_\ell}} \exp\left(-\sum_{i=1}^{\ell} \frac{\lambda_i^2}{2\alpha_i}\right)$$

$$\sum_{i=1}^{\ell} \big(1 - M_i(w(\lambda), w_0)\big)_+ + \frac{1}{2}\sum_{i=1}^{\ell}\left(\ln \alpha_i + \frac{\lambda_i^2}{\alpha_i}\right) \to \min_{\lambda,\alpha}$$

Преимущества и недостатки RVM

Преимущества:

- ⊕ Опорных векторов, как правило, меньше (более «разреженное» решение)
- ⊕ Шумовые выбросы уже не входят в число опорных
- ⊕ Не надо искать параметр регуляризации (вместо этого α_i оптимизируются в процессе обучения)
- ⊕ Аналогично SVM, можно использовать ядра

Недостатки:

- ⊖ RVM не гарантирует улучшения качества классификации

M. E. Tipping. The relevance vector machine. 2000.

C. M. Bishop, M. E. Tipping. Variational relevance vector machine. 2000

Резюме по линейным классификаторам

- *SVM* — лучший метод линейной классификации
- *SVM* легко обобщается и на задачи регрессии
- С помощью *ядер* (kernel trick) SVM изящно обобщается для нелинейной классификации и нелинейной регрессии
- *Регуляризация* увеличивает зазор, устраняет мультиколлинеарность и уменьшает переобучение
- *Аппроксимация пороговой функции потерь* $\mathscr{L}(M)$ также увеличивает зазор и повышает надёжность классификации

Нетривиальный инсайт:

- *Негладкость функции потерь* приводит к отбору объектов
- *Негладкость регуляризатора* приводит к отбору признаков

В. Н. Вапник, А. Я. Лернер. Узнавание образов при помощи обобщенных портретов. 1963.

C. Cortes, V. Vapnik. Support vector networks. 1995.